QCon
全球软件开发大会

InfoQ 技术大会

打造AI时代的工作方式

当模型不再是壁垒：

AI 时代企业级 Agent 与感知硬件的工程实践

易统（任卿）

阿里巴巴 千问办公 副总裁



开场，先抛三个我们都被问过的问题

Agent 已经这么强了，为什么一进企业就变“笨”？

不是模型退化，是它拿不到、也读不懂你独有的上下文。

大家都用同一个大模型，护城河到底在哪？

差距不在参数，在你有没有把物理世界接进 AI 的感知通道。

企业想用，又不敢让 AI 动手，这个矛盾怎么解？

把“可控”做成架构约束，而不是靠人的谨慎。

QCon
全球软件开发大会

InfoQ 技术大会

目录

01 **瓶颈的真相**
模型过剩、上下文稀缺——为什么企业级 AI 的真正战场不在模型

02 **四个硬问题**
感知行为序列 · 业务本体抽象 · 人机双向驱动 · 按岗可定制：Agent 工程化的四道门槛

03 **垂直行业纵深**
以金融为例：把 FDE 交付经验沉淀成“本体”这门长期资产

04 **上下文工程**
Enterprise Context：150PB 数据如何压进 1M 窗口

05 **感知硬件**
当输入从键盘移到嘴边：A2 / EVA 与“数据复利”的判断

06 **可信与全栈**
约束执行、边界取数、私有化全栈——让企业敢把活交出去

01

瓶颈的真相

模型过剩、上下文稀缺——为什么企业级 AI 的真正战场不在模型

都在说组织 AI 转型，一线的真实体感是什么

四个“症状”都不是模型不够聪明，而是工程链路缺了东西。

✕ 聪明，但不懂业务

通用模型什么都能聊，
却答不出“这台泡茶机开不了机怎么处理”。

缺：企业私有上下文

✕ 单点提效，业务却没变快

个人写代码、做图快了，
但跨系统、跨角色的链条照样卡。

缺：端到端可执行

✕ 想用，又不敢用

怕误删、怕越权、怕数据外流，
最终把 Agent 当“高级搜索框”。

缺：可信架构

✕ 缺原料、缺闭环

没有素材、没有反馈回路，
AI 输出接不回真实业务流程。

缺：感知与沉淀

当所有人都能用上同样的模型，差距只来自一件事：

你有没有把“独有的上下文”，稳定地喂给 AI。

过去大家拼的是

模型参数 · 通用能力

→ 正在快速趋同、甚至免费

接下来真正拉开差距的是

私有数据 · 业务本体 · 感知入口

→ 只能靠工程一寸寸沉淀出来

上下文不是玄学，是一个可量化的系统瓶颈

规模差 15 个数量级，任何“塞进提示词”的朴素做法都会失效。

一家中大型企业的真实落差

150 PB

平均沉淀的数据资产

VS

1 M

模型上下文窗口

≈ 15 个
数量级落差

1

“全量塞”必挂

再长的窗口也装不下企业记忆，检索/压缩/图谱是硬需求。

2

上下文要能生长

不止读取历史，还要让每次工作持续沉淀新数据。

3

上下文要被保护

越有价值的数据，越需要权限、审计与隔离。

02

四个硬问题

感知行为序列 · 业务本体抽象 · 人机双向驱动 · 按岗可定制

每一道坎我们都真的踩过、也还在改。
把通用模型跑进企业核心业务，
不是把 prompt 写长一点就行——它需要架构层面的四次跃迁。

门槛 1：让 Agent 看见“你正在做什么”，而不是“你刚说了什么”

Agent 与用户的交互，从“回合制”走向“连续流”。

FROM | 传统做法

被动响应 Prompt

- Agent 只看到最后一次输入
- 无法理解点击、筛选、切换等过程
- 意图丢失，用户被迫反复复述
- 把一次任务当“会话”而非“工作”

TO | 我们的做法

主动识别 GUI 行为序列

- 事件驱动 · 用户操作即上下文
- 持续识别点击 / 筛选 / 拖拽 / 参数调整
- 把行为序列还原成真实研究意图
- 界面同时承载 Agent 的观察与决策

工程判断：不再把用户操作当噪声过滤，而是当一等公民的上下文来建模。

门槛 2：从“线性对话”到“业务本体”，让结构本身可计算

对话流靠用户不断描述结构；本体把结构本身变成 Agent 可操作的对象。

FROM | 传统做法

线性对话 · 结构被压扁

- “分析 A 公司 → 加上 B → 再上估值”
- 自然语言反复补充条件
- 分析逻辑无法复用、无法验证
- 换一个人、换一个问法就得重讲

TO | 我们的做法

业务本体 Ontology

- 实体 Objects · 属性 Properties · 关系 Links
- 操作 Actions · 权限 Security
- 图 / 树 / DAG 承载多维业务结构
- 本体 = 可查询、可写回、可演化的长期资产

工程判断：短期看 Ontology 更贵，长期看它是唯一不会被“下一个模型”淘汰的资产。

门槛 3：从“人操作界面 / 另开窗口问 AI”，到“人与 Agent 互相驱动”

熟悉的 GUI + 后台 ReAct，比“聊天框 + 附件”更符合专业工作的自然节奏。

FROM | 传统做法

GUI 与 Agent 割裂

- 固定功能区，系统被动展示
- 切回聊天框重新描述当前视图
- 复制粘贴复杂格式给 AI
- 认知负担全部落在用户身上

TO | 我们的做法

AI Native 应用 · 双向驱动

- 用户在 GUI 的操作即是对 Agent 的输入
- Agent 在后台 ReAct 观察 · 思考 · 行动
- 分析结果以界面变化实时回流
- 无需切换窗口，人 ⇄ Agent 持续对话

工程判断：LLM 时代的产品形态不是“Chat”，也不是“Copilot 侧栏”，而是 AI Native 应用。

门槛 4：从“一套固定软件”，到“每个岗位自己长出来的 AI Native 应用”

覆盖长尾的唯一路径：把“定制”从开发成本，变成用户自助的日常操作。

FROM | 传统做法

固定软件 · 一套页面

- 固定页面 · 固定数据 · 固定流程
- 机构差异靠二次开发消化
- 岗位方法只能塞进同一 UI
- PM 与开发永远在追赶长尾

TO | 我们的做法

App + Tools + Skills 模块化

- 样板间 + “装修工具”：自然语言二次定制
- 投研 / 投顾 / 信贷 / 保险 各得其所
- 无需研发即可调视图、指标、分析逻辑
- 围绕机构、岗位、个人方法持续生长

工程判断：Agent 应用要有版本号，但更要有“个人版本”，团队版本只是其中一份。

四道门槛合起来，是一次“工作范式”的跃迁



01 回合 → 连续流

把用户操作序列当上下文，Agent 才拥有“手感”。

02 文本 → 本体

把业务结构变成可查询、可回写的对象。

04固定软件 → 按岗生长

自然语言定制，让产品覆盖真正的工作长尾。

03 聊天 → 双向驱动

GUI 是工作空间，不是聊天窗口的附件。

03

垂直行业纵深

以金融为例：把 FDE 交付经验沉淀成“本体”这门长期资产

以金融为例：企业级 Agent 进垂直行业，要跨三道专业门槛

01
让 AI 看懂完整的研究过程

分析师不会先写好一段 Prompt，而是在行情、K线、财务指标、研报之间连续操作。

核心难题
AI 如何理解“你此前做过什么、正在关注什么”？

承接答案
主动识别 GUI 操作行为序列

01
让 AI 理解专业的投研逻辑

一次公司研究涉及公司、财报、研报、指标、估值模型、同业关系，不能压成一张表。

核心难题
AI 如何理解这些对象之间的专业关系与研究方法？

承接答案
金融业务场景本体论抽象

01
让 AI 适应不同机构与岗位

券商、资管、银行与不同研究岗位，数据口径、布局、流程、交付标准各不相同。

核心难题
如何不重复开发，让应用随规则与岗位持续变化？

承接答案
人机双向驱动 + 自然语言二次定制

一个容易被误判的取舍：把能力沉淀成“本体”，而不是“技能清单”

× 普通技能 / 专家市场

- 从市场采购或从项目摘抄
- 逐客户叠加、能力互相打架
- 换一个行业就得重新采购
- 经验停留在单次 Prompt 与交付

✓ 千问办公 · 本体沉淀

① N 家证券 FDE 交付

② 抽象行业全景本体

③ 一次沉淀 · 服务任意行业

④ 跨机构 · 跨岗位 · 跨数据源进化

判断：技能市场是消费型资产，会被下一个模型贬值；本体是生产型资产，是越用越厚的长期壁垒。

交付结果，而不是回答：数字员工的运行时架构与主动性

可执行 · 可协作 · 可进化 —— 从理解意图，到把活办完并回流。

Channel｜交互通道

钉钉 / 千问办公 —— 用户在这里下指令、收结果

Runtime｜托管执行

Managed Agent：规划拆任务 · 调用 Skill/工具 · ReAct 循环

Context｜企业上下文

私有知识 · 数据本体 · 权限 —— 让 Agent 真正懂业务

底座：32 个行情/财务 MCP 工具 · 6 大数据源 400+ 数据工具 · 数据与 Token 合并计费

主动性跃迁：事-人-AI → 事-AI-人

1. **发现异常**
   巡检已授权的经营/业务数据，主动定位问题
2. **主动提醒**
   说明异常、影响与判断依据，不静默
3. **协助处理**
   按授权执行并复查，闭环到结果

04

上下文工程

Enterprise Context：150PB 数据如何压进 1M 窗口

企业上下文 Enterprise Context：让私有知识与 AI 无缝打通

产品我们只讲一件事——它帮企业把数据“连接 · 理解 · 复用”，形成会生长的组织资产。

懂 懂业务

就是懂企业积累了多年的数据
私有知识、口径、规则，一接即懂。

协 能协同

让每一次工作都持续沉淀新数据
上下文越用越厚，组织复利生长。

信

上下文有价值，数据更值得被保护
权限与审计内建在链路里。

▌一个现实约束：中大型企业平均 150PB 数据，而模型窗口只有 1M —— 上下文工程本质是“检索 + 压缩 + 图谱”的系统问题。

连接 + 压缩：把散乱数据炼成 Agent 能用的上下文

01	散落的企业数据	文档 / 表格 / 日志 / 制度 / 现场问答	原始
02	结构化文件系统	清洗、切分、建索引	连接
03	知识图谱 / 本体	实体·关系，可检索、可写回	理解
04	Agent 现场调用	现场问题有据可依	复用

例：线下门店 - 古茗



例：线下门店 - 古茗

古茗门店结构化文件系统

guming-knowledge-base.tree

古茗资料库
- 古茗学院知识框架
  - 门店基础 — 食安 / 稽核 / 开台打烊 / 点单出杯
  - 制作知识 — 后厨 / 调饮 / 配方 / 原料处理
  - 设备知识 — 吧台设备 / 调饮设备 / 后厨设备 / …
  - 营运管理 — 陈列 / 营销 / 政策 / 稽核自检 / …
- 门店运营资料
  - [doc] 【门店宝】支出记账功能
  - [doc] 门店自检及物料订购
  - [doc] 【陈列布置·标准】门店陈列标准手册
  - [doc] 外卖一点通：春节营业锦囊
  - [doc] 【古茗支付】浙商银行贷款支付教程
- 饮品与视频 SOP
  - 香椰泰茶 — 配方文档 / 图片 / 制作视频
  - [video] 冰摇大瓜椰
  - [video] 西瓜椰椰（大 PET 杯）
  - [video] 【古茗周刊】使用指引
- AI 用户体验与需求
  - [spec] AI用户端呈现 — 身份化回答 / 精简结构 / 引用链接
  - [spec] 小古Agent需求 — 学院框架 / 排期 / 权限规则
  - [rule] 权限矩阵 — 角色 × 片区 × 门店设备
- 知识问答评测
  - [report] 古茗知识问答实测报告
  - 12 道测试题 — 操作 / 外卖 / 陈列 / 权限隔离 / 拒答
  - 验证链路 — 检索 → 权限过滤 → 回答 → 引用
- 项目沟通与听记
  - [group] 古茗学院×阿里云 / 小古同学测试 / …
  - [minutes] 多模态检索 / MCP接口 / 交付节点 / …
  - … 共 14 条古茗项目听记索引

古茗门店知识图谱



全栈视角：模型能力 × 企业上下文，才是可交付的智能

单有强模型会“自信地胡说”，单有数据接不进决策——两者要在同一套架构里闭合。

千问模型

接入 Qwen3.8-Omni-Flash
原生多模态 · 长上下文

×

专属 Context 模型

支持企业上下文
压缩、检索与对齐

=

可交付智能

在千问办公 / 钉钉中
现场问题有据可依

05

感知硬件

当输入从键盘移到嘴边：A2 / EVA 与“数据复利”的判断

下一个入口不在屏幕里，在嘴边



上下文，正在取代功能堆叠

语音，正在取代输入框

终端，正在取代流量入口

当所有人都能用上同样的模型，差距只来自一件事：
你有没有把你独有的物理世界，送进AI的感知通道



AI时代，人与人最大的能力差异是数据上下文
我们对AI硬件的理解：

数字世界
物理世界

感知

钉钉
QwenNote

千问办公

AI服务

进化
方向


A1


A1Pro


H1


OBE


pin



B1



BV


Eva
语音AI Agent 移动助理


A2
语音AI Agent 桌面助理

?

?

语音AI Agent随身助理



实时Agent，AI真干活

长按直接说，A2可以干

划时代的AI交互

无需蓝牙

实时同步

6麦

六麦拾音

67g

贴上薄 拿上轻

内置千问办公

语音一键调用

随身指令，IM协同待办

98% 转写准确率

120种语言（含41种方言）

粤语 四川话 普通话 客家话

英语 法语 西班牙语 日语

沟通沉淀

AI纪要总结

知识库沉淀随时调用

不留音频 自在沟通

无痕小绿灯

不保留任何录音文件

00:23:54

无痕听记中



差旅途中

做调研写方案报告



开启同传

当前对话实时翻译



协同办公

标风险点给结论



客户会议后

把纪要发到群里



全场景



语音AI Agent桌面助理

内置千问办公

1台Eva = 1个团队

竞品调研

写脚本

创意策划

多线执行

成果播报

...

Eva，帮我做新品发布会方案

主题定位

提炼新品核心概念

流程策划

发布会全程安排

传播计划

预热与会后扩散

打通 钉钉生态

一句话处理日程、消息、电话、会议等工作，快速执行，立即反馈

自然交互，智能对话

根据对话语境调整语气与表达

Powered by qwen-audio











65W

桌面充电站

3轴

电机云台

适配多端系统

QCon 全球软件开发大会

InfoQ 技术大会

QwenNote A2 — AI里长出来的硬件
不录音、真AI、真干活



实时Agent，
AI真干活

长按直接说，
A2即刻执行



内置千问办公，
语音一键调用

随身指令，
IM协同待办

不留音频，
自在沟通

无痕小绿灯
不保留任何录音文件



沟通沉淀，
AI纪要总结

知识库沉淀随时调用



QwenNote Eva
语音AI Agent桌面助理



全新生命

读懂你的情绪



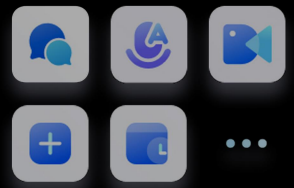
靠谱的工作伙伴

一句话布置复杂任务



AI时代的办公方式

打通钉钉，一说就懂



N种新身份

陪伴学习

打车 买咖啡



QwenNote × 千问办公：从「会记录、会回答」到「会办完」



它能直接交付的东西

- 汇报与调研 PPT
- 小红书爆款抓取分析
- 周报与项目风险清单
- 面试与销售拜访复盘
- 钉钉消息与会议安排

06

可信与全栈

约束执行、边界取数、私有化全栈——让企业敢把活交出去

可信与全栈：把活放心交给它

工程师最怕的不是 Agent 不够聪明，而是它“聪明地闯祸”。
最后一段讲两件事：怎么把可信做成架构，以及这些能力在真实企业里跑成了什么样。



执行操作要有约束：让企业敢把“活”真正交出去

智能体的每一步操作都可控——靠的是三段时间线的架构约束，而不是人的小心。

事前 | 划好界

安全沙箱

执行环境受约束，能力边界先框定

事中 | 有审批

AI 自动审批

操作风险可拦截，高危动作走审批

事后 | 有兜底

文件防误删

误删可防护、可恢复，数据安全有底

接触数据要有边界；能力要能私有化落地

全链路数据安全 + 一个安全中心；底层是阿里 AI 全栈， 支撑强大私有化版本。

全链路数据安全 · 一个中心统一管

权限最小授予	只给完成任务所需的最小上下文
多重访问校验	Agent 读取企业数据前层层核验
敏感识别拦截	命中敏感即拦截，不进入产出
全程留痕审计	从需求→读取→处理→产出可追溯

选择千问办公，是选一套全栈

企业级 Agent 平台

千问办公 · 懂业务 / 能协同 / 信得过

高智能密度模型

千问系列 · 多模态 · 长上下文

自研芯片 · 云底座

阿里云 · 算力与推理自主可控

→ **支持私有化部署，核心业务数据不出域**

先看一个跑在前面的行业：电商的规模化验证

AI 真实落地走在最前列的行业之一 —— 数据不是宣传，是日均在发生的事。

20%

电商付费用户
占平台大盘比例

38 个/周

电商商家用户
周均完成任务数

覆盖经营全场景：
店铺巡检 · 报表分析 · 订单库存 · 素材设计 · 行情监控
跨平台经营作战台 · 数据驱动内容闭环 · 品牌级素材量产 · 跨平台 ROI 智能盯办

三位商家的 AI 经营实践

捌比特咖啡

零代码改革派

重构选品、数据、财务全流程

年入 2000 万

产业带女鞋商家

趋势爆品急先锋

从发现热点到开店只用

7 天

个人电商操盘手

效率提升真王者

2 人撑起 1 万张素材，压缩

80% 时间

跨平台 经营统筹

汇总已支持平台的经营信息，关联分析销售、库存、退款与投放。

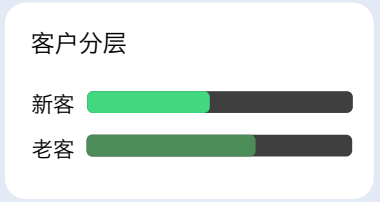


跨平台经营作战台

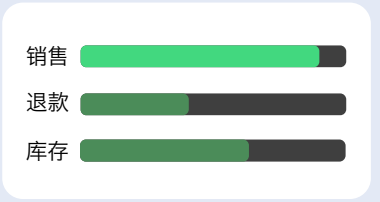
跨平台经营　异常告警　活动日历



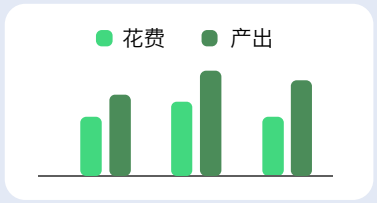
经营全景分析



用户价值洞察



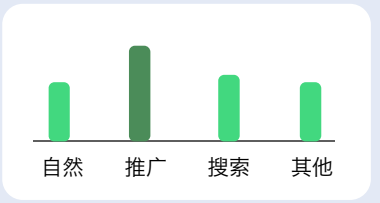
商品经营分析



推广投产分析



经营异常监控

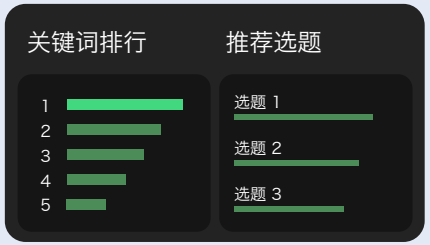


流量承接分析

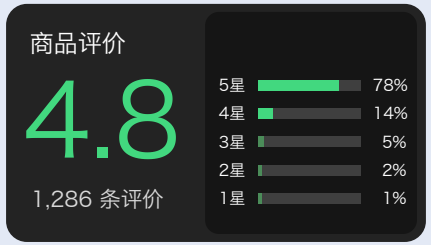
集中查看整体表现，确定补货、投放和异常处理的优先级

数据驱动 内容闭环

根据经营数据判断优化方向，批量准备商品与营销内容



为商品找热点



评价分析

素材诊断优化

检查素材规范，给出优化建议

素材裂变：基于已有素材生成更多版本

01 **发现问题**

识别商品流量或转化下滑

02 **分析优化方向**

结合搜索趋势、用户偏好与经营数据

03 **批量生成内容**

标题、卖点、详情页文案与营销素材

把经营分析用于内容制作与优化

品牌级 素材量产

按品牌要求，批量生成适配不同品类与渠道的图片和视频



商品套图批量生成

电商主图　批量套图　国内外平台

01 **统一品牌风格**

预设品牌色彩、视觉风格与核心卖点

02 **适配不同品类与渠道**

制作商品主图、套图与营销素材



保持品牌风格一致，减少重复制作

跨平台 ROI 智能盯办

按设定的目标和时间，持续跟踪投放表现



投放 ROI 智能优化

广告投放　智能诊断　多平台

01 采集投放报表

汇总跨平台投放数据

02 跟踪目标达成

按定时任务检查投放表现

03 提醒异常变化

关注 ROI 下滑和预算消耗异常

04 给出优化建议

辅助判断投放调整方向

从大促备战到活动复盘，减少逐个平台查看报表的工作

三位商家的 AI 经营实践

零代码基础改革派

捌比特咖啡 8bitcafe

重构选品、数据、财务全流程

年入2000万咖啡销售

趋势爆品急先锋

产业带女鞋商家

从发现热点到开店只用 7 天

压缩 80%时间

效率提升真王者

个人电商操盘手

2 人撑起 1 万张素材

干完15人4个月的活

AI销售铁军---助力某互联网客户销售人效2倍提升，实践案例



拥有千人一线销售团队、服务几十万商家；业务覆盖全国主要城市的酒店门店，门店线下拜访是主要场景，当前面临。
推广使用 1.5个月，系统建设与见效果约6个月，沉淀10万+数据　洞察业务及服务销售

2 倍+
销售人效对标竞对（新人场景为主）

3 倍
新人谈判成功率（落地后对比落地前）

1 个月
新人学习周期（原2-3个月）

+70%
业务增长（同期行业零增长）

签到唤起A1听记 → 签出关闭并上传 → AI摘要自动生成 → 自动填入拜访小记

环节	Before	After
记录	手机录音执行率低、来电中断即丢失	签到即录、4G直传、自动关联拜访
拜访小记	每天手工填写10分钟-1小时	摘要自动填充，减少到几分钟
新人培养	师兄陪访+晚会复盘，2-3个月才能谈成	Agent对练+现场辅助，1个月达标
管理陪访	每月完成全团队比例陪访，东跑西跑	听录音看摘要远程辅导，陪跑取消

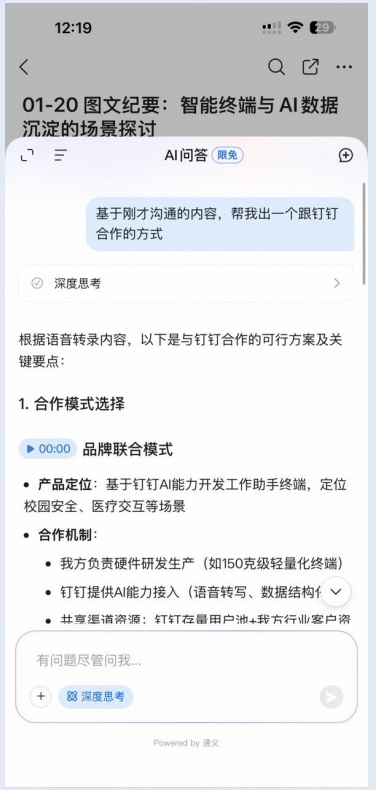


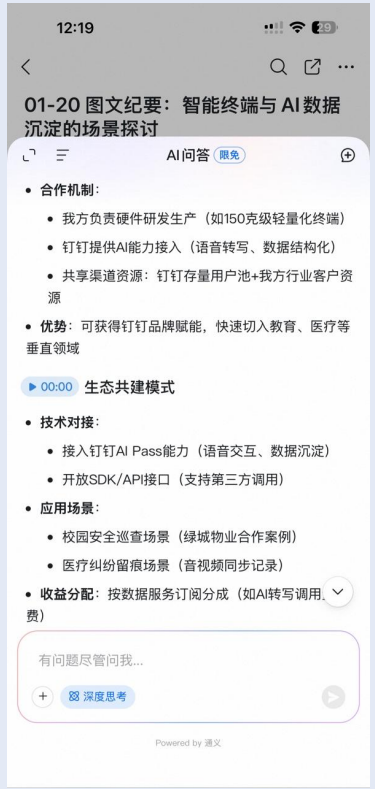
QCon 全球软件开发大会
InfoQ 技术大会

销售拜访，听记结束、合作方案即刻生成

基于A1的一线现场沟通数据及历史上下文内容的方案立现







四个判断

01 瓶颈已经转移

别再迷信“换个更大的模型”。企业级 AI 的瓶颈，正从模型能力转向上下文工程。

02 资产需要重定义

技能会随模型贬值，本体与数据才会复利。把一次性交付沉淀成可演化的资产。

03 入口正在迁移

感知硬件不是产品的配件，而是数据护城河的前哨。输入，正从键盘回到嘴边。

04 可信先于聪明

企业级 Agent 的胜负手，是“敢不敢让它动手”，不是“它答得多漂亮”。

AiCon 北京站

全球人工智能开发与应用大会

探索 AI 应用边界

Explore the limits of AI applications

2026 年 12 月 18-19 日 / 北京新云南皇冠假日酒店

参会咨询

专题：Post-Training Engineering | 数据、奖励与模型能力塑造

专题出品人：余瑶

飞猪 / 资深算法专家



专题：大模型推理与算力调度实践

专题出品人：范苑

阿里云 / 专有云计算产品负责人



专题：Knowledge Engineering | 让 Agent 理解企业

专题出品人：盛茂家

火山引擎 / Viking 团队技术负责人



专题：Loop & Graph Engineering

专题出品人：孙子荀

腾讯 / 腾讯高级总监



专题：AI 原生架构的演进与治理

专题出品人：刘中兵

快手 / 架构治理团队 & AI 架构演进负责人



专题：Agentic Software Engineering | 从代码生成到软件交付

专题出品人：杨杰

荣耀 / 首席 IT 技术架构师



QCon 全球软件开发大会

InfoQ 技术大会

QCon
全球软件开发大会

InfoQ 技术大会

THANKS

