QCon
全球软件开发大会

InfoQ 技术大会

面向硬件场景的智慧视频创作 Agent 规模化落地实践

李琳琳

小影科技 业务VP



QCon
全球软件开发大会

InfoQ 技术大会

目录

01 从一键成片到 Agent：需求与工程挑战

02 为什么选择端云协同架构

03 从素材理解到视频执行的核心技术

04 规模化落地实践与技术反思

01

从一键成片到 Agent：需求与工程挑战

为什么自动剪辑还不能完全解决大众用户的视频创作问题

拍摄已经足够简单，难的是把素材变成一个故事

影像能力演进：能力趋同，体验升级

拍摄能力提升

- 多摄系统普及，硬件参数持续升级
- 计算摄影优化，画质接近物理极限



AI 能力普及

- AI 影像算法成为标配
- 场景识别、修图、美颜全面普及



高端手机摄影

- 旗舰机型影像能力全面领先
- 用户拍摄体验接近专业设备



Pocket 设备

- 形态创新，体验升级
- 轻便携带，随手记录



硬件厂商：具备用户入口与影像素材优势，软件层体验成为新的增长点

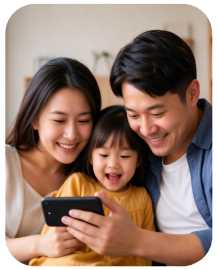
用户行为变化：拍得越来越多，创作越来越少

拍摄量	照片堆积	视频堆积	内容创作
持续增长	快速增长	快速增长	持续下滑



旅行场景

随手拍摄，记录美好瞬间
照片和视频大量积累



家庭场景

珍贵时刻，用影像记录
存储在相册，很少回看



Vlog 场景

拍摄容易，剪辑复杂
创作门槛高，难以坚持

大众用户：存在持续的日常表达诉求，但从素材记录到视频创作仍存在门槛

解决方案：以 Agent 能力提升终端视频创作体验

面向每一个普通用户，让手机相册里的素材，通过 AI 理解、故事规划和专业剪辑能力，自动生成有情感、有主题、高质量的视频。

用户输入

一句话需求/原始素材



用户需求：
“帮我把上周旅行的照片和视频做成一个3分钟、有故事感的Vlog”



Agent 理解与规划

AI Agent 创作决策

- 意图理解
- 素材分析
- 选择 Story Skill
- 生成故事结构
- 输出创作配置

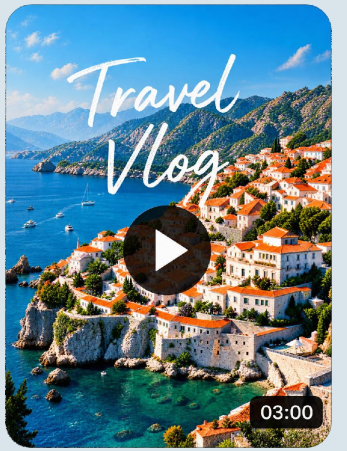
执行生成

调用专业视频能力

- 素材解析与加载
- 剪辑编排
- 特效渲染
- 音频处理
- 多设备适配

生成精彩视频

有主题、有节奏、可分享



关键技术能力　端侧视觉感知 | 端侧 VLM | Story Skill | 视频编辑 SDK

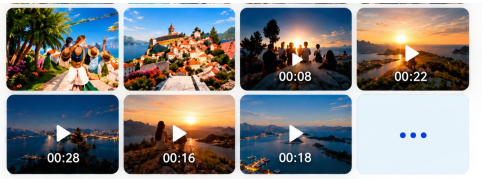
用户价值　更简单、更有故事
更高质量、更个性化

终端视频 Agent 面临的挑战

要在手机上真正实现“从海量素材到有故事的视频”，需要同时突破数据、算力、体验和专业能力的多重工程挑战。

1 海量本地素材

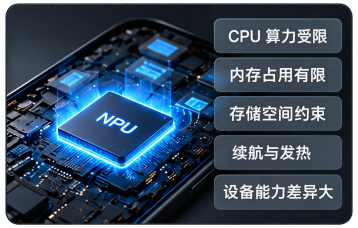
1W+ 照片　500+ 视频片段　100+ 音频片段



工程挑战

- 本地相册可能有成千上万的照片和视频
- 不适合每次全量上传到云端分析
- 需要在本地快速检索、筛选和理解关键信息

2 终端资源有限



工程挑战

- 不同机型的芯片、内存、存储和功耗差异大
- 大模型无法直接在端侧完整运行
- 需要根据设备能力动态分工
- 既要保证效果，又要控制功耗和用户体验

3 创作意图开放


“帮我把上周旅行的照片和视频做成一个3分钟的Vlog”


“记录孩子的成长瞬间做成温馨的家庭纪念片”


“制作一段演唱会回忆视频”

工程挑战

- 用户需求多样，目标不固定
- 需要理解用户意图、场景和情绪
- 选择合适的故事策略
- 同时保证生成视频有主题、有情感、有节奏

4 专业视频创作复杂



工程挑战

- 视频创作涉及多种专业能力（剪辑/调色/音乐/字幕/特效...）
- 需要输出可播放的高质量成片
- 各环节参数配置复杂，端侧难以完成全部处理
- 既要保证质量，又要控制生成时间和资源消耗

不能简单采用“大模型 + 视频工具”的通用架构

02

为什么选择端云协同架构

端云协同的视频创作 Agent 架构与执行链路

用户需求 帮我用上周旅行的照片和视频，做一个有故事感的短片

01 端侧 | 素材理解



本地图库检索
时间 · 地点 · 素材元信息

视觉算法
人物 · 场景 · 高光 · 画质

端侧 VLM
图片/采样帧理解

素材信息组织
关键理解结果、时间与素材引用

Media Context
内容描述 · 素材关系 · 文件与片段定位

上传 Media Context

结构化素材上下文

02 云端 | 创作规划

Agent Planner
理解目标 · 选择能力

Story Skill
场景策略 · 专业规则 · 素材约束

故事与剪辑规划
章节 · 选材 · 节奏 · 音乐 · 包装

Creative Config
可执行的创作配置

下发 Creative Config

创作意图与执行约束

03 端侧 | 视频执行

配置解析与校验
素材可用性 · 资源与设备兼容

Timeline 构建
素材映射 · 视频/音频/字幕轨道



专业视频 SDK
剪辑 · 特效 · 音频处理

渲染与导出
本地视频文件



Workflow | 任务过程管理 任务编排 | 状态与进度 | 超时重试与失败恢复

为什么不是纯云端，也不是纯端侧？

视频创作需要同时处理海量个人素材、复杂语义理解和高质量渲染，仅靠云端或仅靠端侧都无法满足体验、成本和隐私的综合要求。

纯云端方案的局限

数据量大
用户相册动辄成千上万的照片视频

云端成本高
涉及大量用户个人隐私内容

传输与隐私风险
存储、带宽、GPU 推理、渲染成本高
难以支撑大规模用户

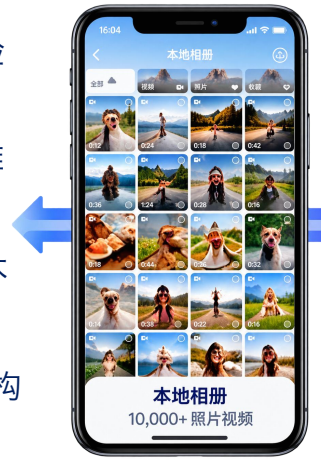
依赖弱网环境
弱网/无网时无法使用，体验不稳定

无法满足用户对“隐私、安全、速度和成本"的要求

端云协同：根据任务特征分配能力

端侧

- 本地素材检索与理解
- 轻量模型推理
- 隐私数据本地处理
- Timeline 构建与渲染
- 离线可用，实时响应



云端

- 复杂意图理解
- 故事规划与策略生成
- 长文本/多知识推理
- 高质量素材/音乐/特效
- 模型与内容库持续更新

纯端侧方案的局限

算力、内存、功耗受限
无法运行大规模多模态模型

复杂语义推理能力弱
难以理解抽象的用户意图
(如“做一个有故事感的旅行视频")

专业内容资源有限
高质量特效、音乐等难以长期维护

视频编辑与渲染能力有限
复杂特效、画质增强等需要专业 SDK

无法满足用户对“创意理解、内容质量和丰富效果"的要求

异构终端适配：基于设备能力动态调整任务执行

在同一套 Agent 架构下，以端侧内容理解为默认执行链路，并根据设备能力进行能力降级。

创作任务输入 → 端侧内容理解 (默认执行) → 云端故事规划 (按需执行) → 端侧编辑与渲染 (默认执行) → 最终视频作品

统一的 Runtime 动态路由，根据设备算力、内存、网络条件和任务复杂度，动态调整任务分配：



旗舰机（高端设备）

- 可运行完整视觉算法与端侧 VLM
- 响应快、云端带宽成本低

端侧完整内容理解+复杂策略执行

端侧内容理解	云端故事规划	端侧编辑渲染
视觉算法+端侧VLM生成完整Media Context	Story Skill、生成Creative Config	完整功能执行、本地导出成片



中端机（标准性能设备）

- 可运行轻量视觉算法与小规模端侧 VLM
- 在体验、效果、成本之间取得较好平衡

端侧轻量化理解+云端复杂规划

端侧基础理解	云端故事规划	端侧编辑渲染
轻量视觉算法筛选关键素材	Story Skill、生成Creative Config	基础剪辑与特效本地导出成片



入门机（资源受限设备）

- 无法运行端侧 VLM
- 保证基本体验与可用性

轻量本地处理+云端能力为主

端侧轻量处理	云端理解规划	端侧编辑渲染
提取基础Metadata	视觉理解+VLM生成Creative Config	基础剪辑与模板本地导出成片

Agent 负责决策，Skill 提供专业能力，Workflow 保障执行



创作规划可以灵活，执行接口必须明确，任务过程必须可管理。

03

从素材理解到视频执行的核心技术

端侧工程底座：支撑素材理解与视频执行

视觉算法提取素材特征并组织语义，专业视频 SDK 执行成片



端侧内容理解：从海量素材中提取结构化信息

基于高效的端侧视觉识别算法，从用户相册中提取结构化、有语义的 Media Context，为后续的故事规划提供高质量输入。

1 如何降低需要分析的素材规模?



利用相册索引、时间地点、元数据进行候选集筛选

从 120 项原始素材中筛选出 30% 的候选片段

2 如何高效提取视觉特征?

自适应视频采样
根据视频时长动态调整抽帧帧率与分析策略

多维特征分析
场景、人物、动作、画质、情感、音频等特征提取

高光筛选与评分
基于综合得分选择高价值片段

结构化特征输出
输出片段级语义特征

视觉特征提取示例



场景：迪士尼
人物：妈妈 / 女儿
动作：入园
情感：兴奋
画质：0.89
高光分：0.82

在控制计算量的同时获取有效素材信息

3 如何输出 Media Context?

输入



场景标签	旅行 / 城市 / 景点
人物检测	3人（妈妈、女儿、爸爸）
时间信息	Day1 - Day3
动作事件	入园 / 游玩 / 合影 / 日落
质量与高光	高光片段 36 段

输出（示例）

```
{
  "events": [
    {
      "event_id": "e1",
      "type": "arrival",
      "time": "day1",
      "location": "迪士尼",
      "people": ["妈妈", "女儿"],
      "summary": "入园，开启旅程",
      "clips": ["v1", "v3"]
    },
    {
      "event_id": "e2",
      "type": "scenery",
      "time": "day1",
      "location": "城堡",
      "summary": "城堡打卡",
      "clips": ["v5", "v8"]
    }
  ],
  "characters": [
    {"id": "p1", "name": "妈妈", ...},
    {"id": "p2", "name": "女儿", ...}
  ],
  "summary": "一次充满欢乐的迪士尼之旅"
} ...
```

端侧处理性能（示例）

- **候选集检索** <1秒（基于相册索引）
- **视频特征提取** 约 40-70ms/段（自适应采样）
- **语义组织** 约 1-2秒（生成Media Context）
- **输出大小** 约 200-500 KB（结构化数据）

故事策略驱动：如何让 Agent 生成有故事感、又符合真实素材的视频?

1 理解用户需求与素材特点



用户需求:
“帮我把上周旅行的照片和视频做成一个3分钟、有故事感的Vlog

100 张照片
(约 500 MB)

20 段视频
(约 2.5 GB)

选取可用素材、分析素材特点与创作约束:

- **多地点** 海边 / 城市 / 美食
- **多人** 家人 / 朋友
- **内容丰富** 风景 / 人物 / 日常
- **存在不足** 较少“出发”镜头

2 选择 Story Skill 与创作策略

基于素材特点和用户意图，选择最匹配的场景Story Skill

- **旅行** (已选)
- **亲子**
- **演唱会**
- **日常**
- ...

创作策略示例:

- **故事结构** 以行程变化为主线，融入人物互动和情感表达。
- **素材使用** 优先选用高光时刻、人物互动镜头、地标场景。
- **内容重点** 突出旅行亮点、亲子时刻、美食体验、风景画面。
- **节奏与时长** 3 分钟, 开场 - 行程 - 高潮 - 结尾。

生成故事结构与素材映射:



3 输出可执行的创作配置

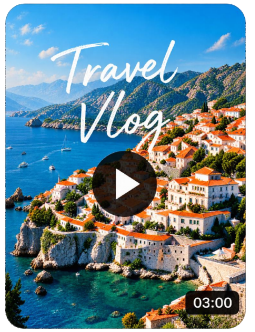
将故事规划转化为结构化 Creative Config，确保每个片段都能映射到真实素材



4 基于配置生成并评估视频作品

完成剪辑、调色、音乐、字幕、特效处理

综合素材合理性、故事完整性、用户反馈等评估创作效果



核心技术支撑

- **多模态内容理解** 图像/视频/音频统一理解
- **故事规划与生成** 场景识别/人物分析/叙事架构
- **素材匹配与约束优化** 根据真实素材动态调整方案
- **结构化输出** 可执行的创作参数与时间线
- **效果评估** 基于用户反馈和数据优化

从创作经验到 Story Skill：让专业规则可调用、可复用、可评估

以亲子场景 Story Skill 为例：

1 输入 | 明确本次任务

任务目标 + 可用素材

用户要求
视频时长、想表达的感受

素材信息
成长阶段、家人互动、场景覆盖

2 规则 | 指导创作决策

可复用的专业经验

选材优先级
优先保留家人互动与重要成长时刻

组织方式
围绕成长脉络安排故事与情绪

3 约束 | 限定可行范围

规划必须满足的条件

素材可追溯
每个片段都能对应到真实素材文件

执行有边界
总时长符合要求，效果适配设备能力

4 输出 | 形成执行方案

从规划到端侧执行

故事规划
说明故事顺序、段落与重点

创作配置
明确素材安排、时长及视听要求

Story Skill 的创作规则可复用。更换相册素材或用户需求后，Agent 将快速重新生成对应的故事规划与创作配置

从视频产品经验到 Agent Skill：专业创作知识如何持续沉淀？

1 真实创作行为与数据

来自全球用户的真实创作需求



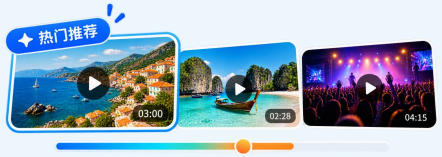
“帮我把上周旅行的照片和视频做成一个3分钟的Vlog”



“记录孩子的成长瞬间做成温馨的家庭纪念片”



“制作一段演唱会回忆视频”



创作经验沉淀

2 专业知识创作工程

将优质创作经验转化为可复用的 Agent Skill

- **故事分析**
  场景理解/主题提炼/情感基调
- **高光识别**
  人物/风景/动作等亮点片段筛选
- **叙事结构**
  起承转合/节奏控制/时长分配
- **内容生成**
  素材选择/片段组织/转场字幕
- **风格化表达**
  音乐风格/画面调色/字幕模板

服务创作实践

3 Skill 持续选代

生成更符合用户需求、更有故事感、更高质量的视频



小影科技产品经验积累

VivaVideo　Rythmix　AI Catch　VivaCut　mAst

14年+	200+	23亿+	1亿+
深耕沉淀	国家和地区覆盖	全球累计下载量	月活跃用户

Skill 工程化运营

版本管理	效果评估	数据反馈	持续优化
策略版本 A/B 灰度 场景迭代	完播/互动率、 用户留存	用户行为采集 问题反哺规则	沉淀创作经验 扩展场景与机型

Creative Config：如何将 AI 创作决策转化为专业剪辑操作？

云端输出 Creative Config

```
{
  "project": {
    "theme": "travel_vlog",
    "duration": 180,
    "storyline": [
      {"chapter": "opening", "title": "出发",
       "assets": ["video_01", "photo_03"]},
      {"chapter": "journey", "title": "旅途",
       "assets": ["video_02", "photo_10"]},
      {"chapter": "highlight", "title": "高光", ...}
    ],
  "music": {"id": "music_001", "start": 0},
  "style": {"template_id": "tpl_travel_01"},
  "effects": [{"type": "filter", "id": "F01"}],
  "subtitle": {"enable": true, "style": "vlog"}
}
```

故事结构
章节/时长

视觉风格
滤镜/特效

音乐音效
BGM/转场音

字幕与贴纸
样式/位置/时长

① 端侧解析与 Timeline 构建

配置解析
校验配置合法性

素材匹配
本地素材与配置关联

Timeline 构建
生成多轨道编辑时间线

资源加载
模板/滤镜/贴纸/音乐

执行校验
时长/转场/资源完整性

Timeline 示例



② 端侧调用专业视频编辑 SDK 执行

素材解析与加载
支持多种视频/图片格式

轨道合成
多轨道混合、转场处理

特效渲染
滤镜、贴纸、字幕、动画

音频处理
BGM、音效、音量平衡

渲染与导出
生成高质量视频文件

关键技术支撑

高性能渲染
GPU/Metal 多线程加速

资源管理
模板/贴纸/音乐按需加载与缓存

端云一致性
统一 Creative Config 保证跨端效果一致性

稳定执行
任务监控/异常处理/断点恢复

如何验证视频 Agent 真的比传统一键成片更好?

对比验证表明：基于 Agent 的创作方式在多个维度上显著优于传统方案，能够帮助用户快速生成故事感视频。

1 内容质量：素材是否合理?

传统一键成片 VS Agent 创作

叙事完整度	40% ⟶	80%
素材使用有效率	60% ⟶	90%
画面质量	60% ⟶	90%

主题更明确、叙事更完整



传统一键成片

2 效率提升：内容是否形成可理解的故事?

传统一键成片 VS Agent 创作

故事结构完整度	40% ⟶	85%
内容可理解性	45% ⟶	90%
平均耗时（单条）	8.2分钟 ⟶	3.1分钟

更符合用户观看习惯、效率显著提升



Agent 创作

3 创意表现：剪辑、音乐、表达是否生动?

传统一键成片 VS Agent 创作

节奏匹配度	50% ⟶	90%
创意元素丰富度	45% ⟶	90%
视觉表现力	55% ⟶	90%

智能组合，创意表现更丰富

4 用户体验：操作是否简单、好用?

传统一键成片 VS Agent 创作

操作步骤	3步 ⟶	1步
用户满意度	60% ⟶	95%
学习成本	10分钟 ⟶	3分钟

对话式输入，用户体验更友好

* 数据源自内部旅行视频素材测试，非公开基准测试

一次真实创作：从一句话到一个有故事的视频



04

规模化落地实践与技术反思

硬件厂商合作：从智慧成片迈向 Agent 创作

荣耀

- **合作背景：**
  荣耀终端拥有海量用户相册素材，希望打通手机拍摄与剪辑链路，让普通用户轻松完成视频创作。

- **已有合作成果：**
  基于 MagicOS 打造系统原生“智慧成片”功能，覆盖荣耀全系列机型（包括畅玩、数字、旗舰、折叠屏、Pad 系列）



87% 视频制作率	185% 次日留存
784% 一键大片带来用户增量	3000+ 丰富的素材内容持续更新

海外终端厂商

- **合作背景：**
  面向海外新兴市场，客户希望为本地用户提供贴合本土审美的系统级剪辑创作能力。

- **已有合作成果：**
  输出音视频剪辑+智慧视频创作整套能力，适配不同国家和地区用户创作偏好。



Agent 创作能力即将上线

在既有终端视频创作服务的基础上，进一步落地由 Agent 驱动的相册创作体验，让全球更多大众用户轻松表达。

终端视频 Agent 的三大实践思考

1. **把计算放在合适的位置**

   视觉算法提取特征、组织语义，云端进行复杂创作规划。

2. **让专业经验进入 Agent 决策**

   通过场景化 Story Skill，在模型灵活性与专业创作要求之间建立约束。

3. **让智能决策与稳定执行解耦**

   云端生成 Creative Config，端侧视频引擎完成 Timeline 构建及专业渲染。

Agent 的价值不仅来自模型能力，也来自内容理解、专业知识和工程系统的协同。

AiCon 北京站

全球人工智能开发与应用大会

探索 AI 应用边界

Explore the limits of AI applications

2026 年 12 月 18–19 日 / 北京新云南皇冠假日酒店

参会咨询

专题：Post-Training Engineering | 数据、奖励与模型能力塑造



专题出品人：余瑶

飞猪 / 资深算法专家

专题：大模型推理与算力调度实践



专题出品人：范苑

阿里云 / 专有云计算产品负责人

专题：Knowledge Engineering | 让 Agent 理解企业



专题出品人：盛茂家

火山引擎 / Viking 团队技术负责人

专题：Loop & Graph Engineering



专题出品人：孙子荀

腾讯 / 腾讯高级总监

专题：AI 原生架构的演进与治理



专题出品人：刘中兵

快手 / 架构治理团队 & AI 架构演进负责人

专题：Agentic Software Engineering | 从代码生成到软件交付



专题出品人：杨杰

荣耀 / 首席 IT 技术架构师

QCon
全球软件开发大会

InfoQ 技术大会

THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The Software

人才招聘：https://fireflyfusion.jobs.feishu.cn/index
投递邮箱：hr@fireflyfusion.cn



联系方式