QCon
全球软件开发大会

InfoQ 技术大会

软件工程的下一步

-- 真实世界的 AI 软件交付

许晓斌

阿里巴巴 – 研发基础设施负责人



软件交付的瓶颈不再是 Coding

在阿里巴巴，编码占用软件交付时长普遍在 20%-30%



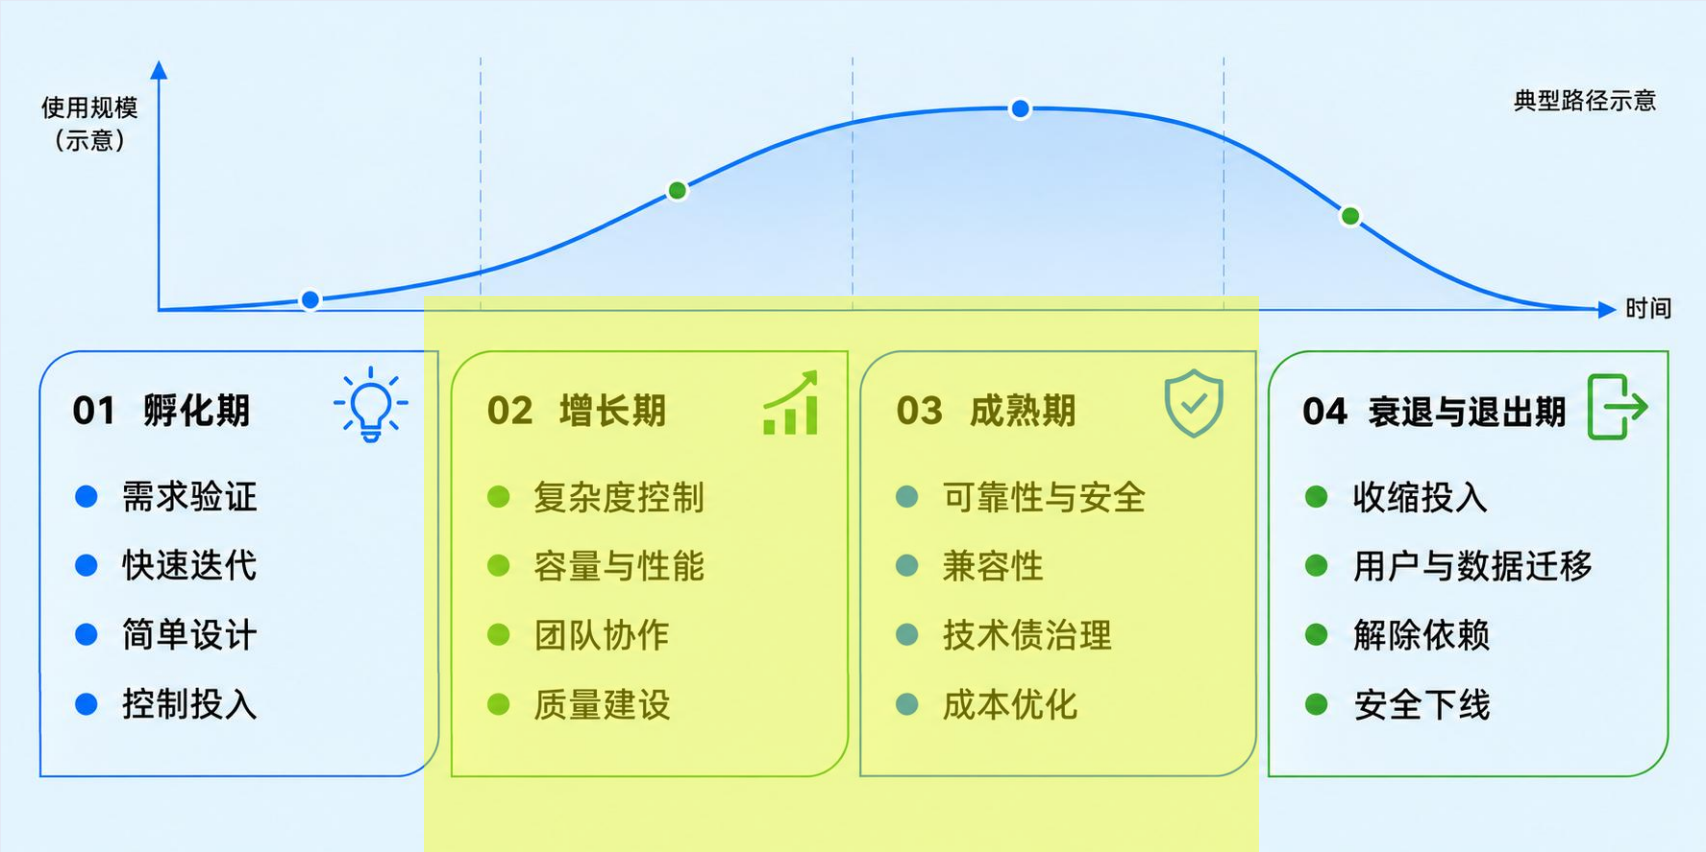
软件工程的核心问题

Software engineering != Coding

问题简述	详细解释	引用材料
需求与价值：做对的事	将模糊、冲突的诉求转化为可验证的目标，确认软件真正解决用户问题。	Nuseibeh & Easterbrook（2000）《需求工程路线图》
复杂性：让系统可理解、可掌控	通过抽象、模块化和接口控制依赖，使局部可以独立理解，整体行为可以分析。	Brooks（1987）《没有银弹》；Parnas（1972）模块化分解
质量与可信性：有证据地保证可靠	通过测试、验证与运行观测，判断功能、性能、安全等要求是否满足，以及剩余风险是否可接受。	IEEE CS（2024）《SWEBOK v4》，测试、质量与安全知识域
持续演化：让软件长期可改	适应需求和环境变化，控制复杂度与技术债，使软件持续有用，修改成本保持可承受。	Lehman（1980）《程序、生命周期与软件演化规律》
多人协作：让局部工作形成整体	协调团队之间的知识、任务和技术依赖，使分工开发的成果能够一致、正确地集成。	Herbsleb（2007）《全球软件工程：社会技术协调的未来》
经济与风险：在约束下合理取舍	权衡价值、成本、工期与质量，优先消除关键风险，确定先做什么、投入多少、何时交付。	Boehm（1988）《软件开发与增强的螺旋模型》

不同生命周期阶段的问题视角

孵化期软件工程问题的解决 != 增长期和成熟期软件工程问题的解决



真实案例

现象：分布式限流系统出现特定场景失效，导致流量过载

背景：这个系统已经稳定运行了5年以上，期间核心代码逻辑没做过改动

根因：
1. 多年前的代码中有针对特定场景应用的 if 白名单逻辑（原因已不可查）
2. 生产系统因为机器配置升级导致机器数量降低
3. 外部变化（机器数降低）+ 内部特殊逻辑，触发 bug



我们当前的使用 AI 的方法对此类问题：无能为力

如何控制软件质量?

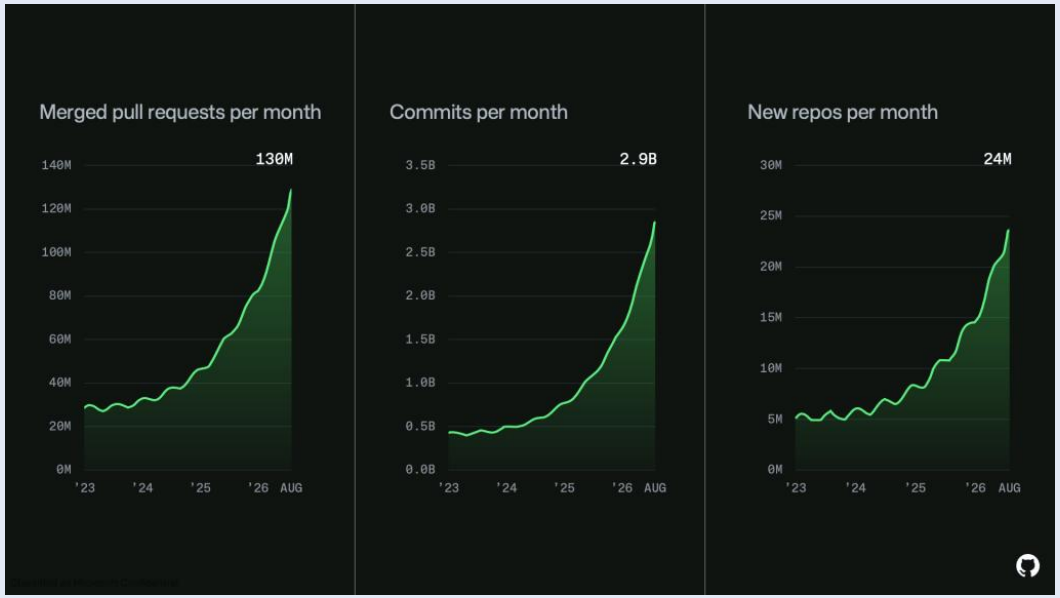
先看一组数据

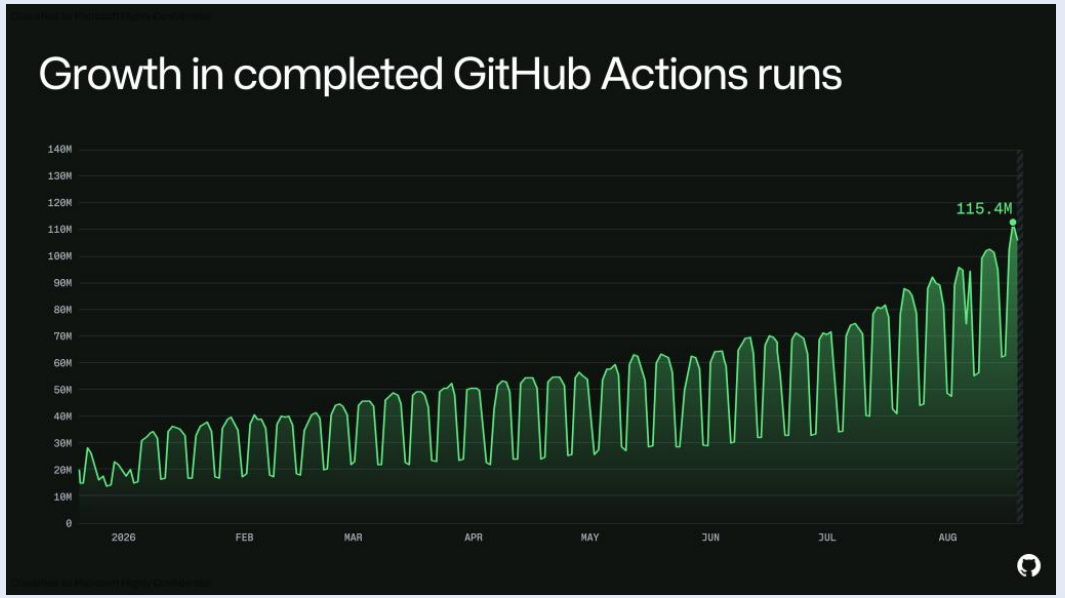
研发基础设施变得对人“不可见”了，但是 Agent 使用的频次在不断增长



Github 基础设施承压

The August 17 outage, and the work ahead





https://github.blog/news-insights/company-news/the-august-17-outage-and-the-work-ahead/

质量控制为何重要

相比孵化期的软件，增长期和成熟期的软件，质量问题带来的损失是数千数万倍。



关键判断：

1. 我们需要更高频次的质量验证。 10-100 倍!
2. 我们需要更完整范围的质量验证。从 code review，ut，到接近真实环境。
3. 我们需要控制验证风险。

主流 Bench 在验证环境上的水平

Benchmark	实际提供的验证环境	如何判断完成	对生产验证仍缺什么
SWE-bench / Verified	真实代码仓库、指定历史版本、依赖与 Docker 执行环境	检查问题相关测试从失败变成功，以及指定回归测试继续通过	主要围绕指定问题和测试集；生产拓扑、真实流量、长时间运行、发布与恢复并非统一要求
Terminal-Bench 2.0/2.1	每道题专属容器、工具、文件和资源配置；框架可支持复杂环境编排	任务专属 verifier 检查产物、行为或环境状态	完整程度取决于单题；有数据库或网络任务，不代表全套任务都验证多服务、并发和业务一致性
SWE-Bench Pro	多语言真实仓库、构建工具、依赖及预构建容器；补充需求和接口说明	人工审查的修复测试、回归测试，并重复运行参考解校验环境	任务复杂度提高，仍主要是仓库内测试；不会自然获得生产数据、拓扑和负载真实性
SWE-Lancer	Expensify 应用环境、浏览器交互、Docker；公开版本调整为离线运行	编程任务用隐藏的 Playwright 端到端测试验证用户流程	任务集中于一个应用；基础设施故障覆盖有限，离线成功也不能代表线上外部依赖可用
AIOpsLab	实际运行的微服务、Kubernetes、数据库/缓存、负载生成、故障注入及遥测	按任务判断发现、定位、根因分析或恢复；恢复任务还检查整体系统状态	属于运维评测；预设应用和故障库仍有边界，不能替代企业真实数据、完整业务约束与长期运行验证

我们的一些工作



Open CodeReview （已开源）

https://github.com/alibaba/open-code-review



Open Sandbox （已开源）

https://github.com/opensandbox-group/OpenSandbox

Aone Guardrail （未开源）

Aone Ground （未开源）

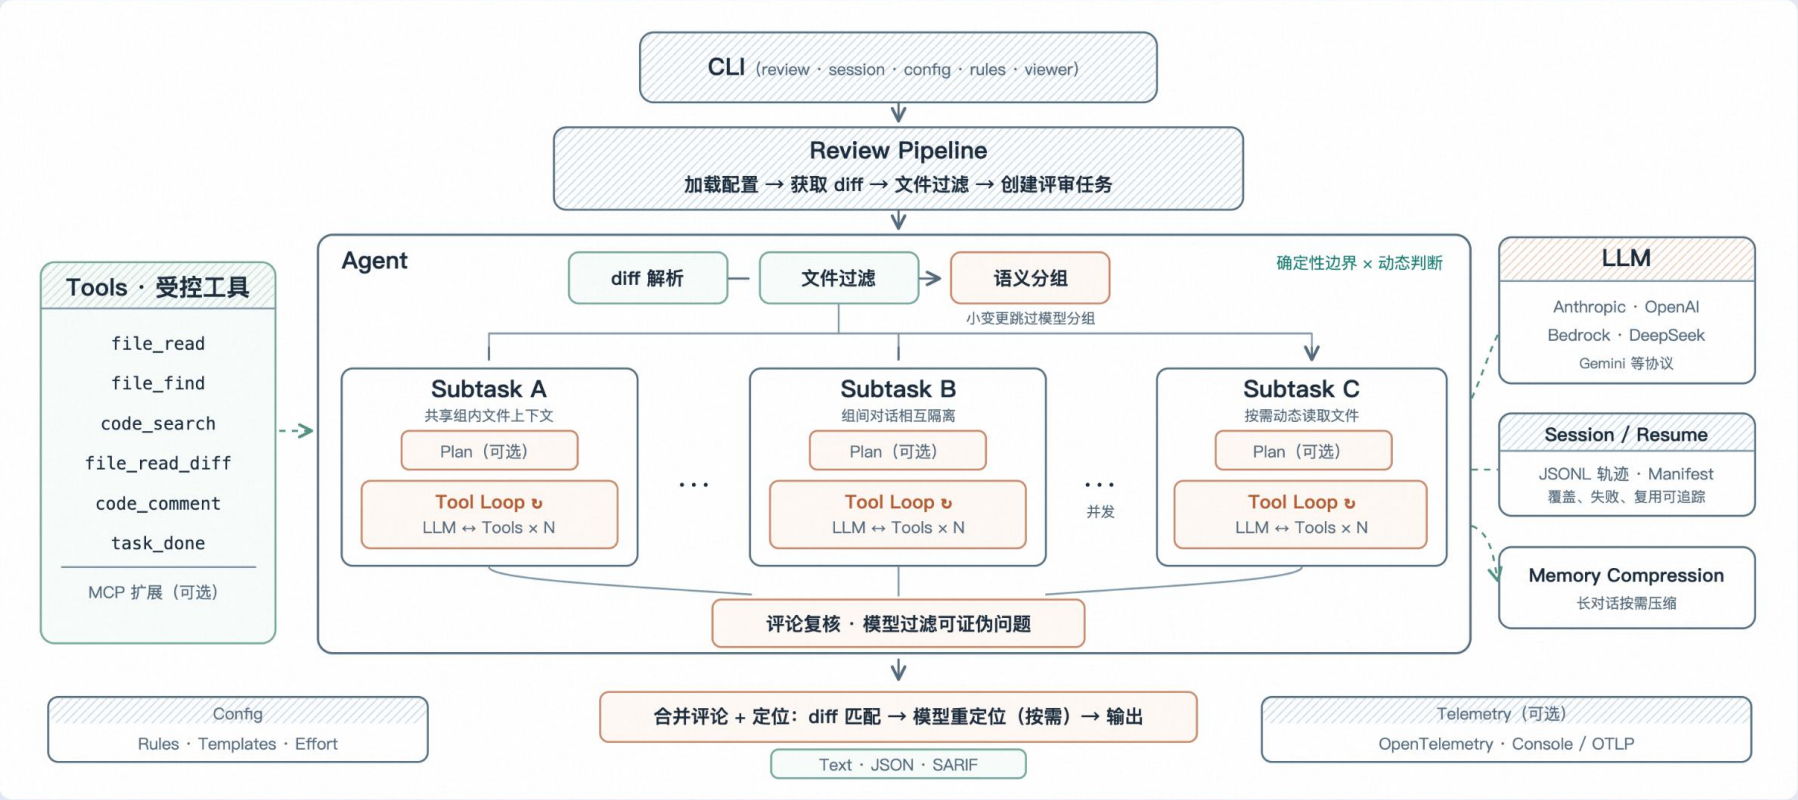


Open AgentAuth （已开源）

https://github.com/alibaba/open-agent-auth

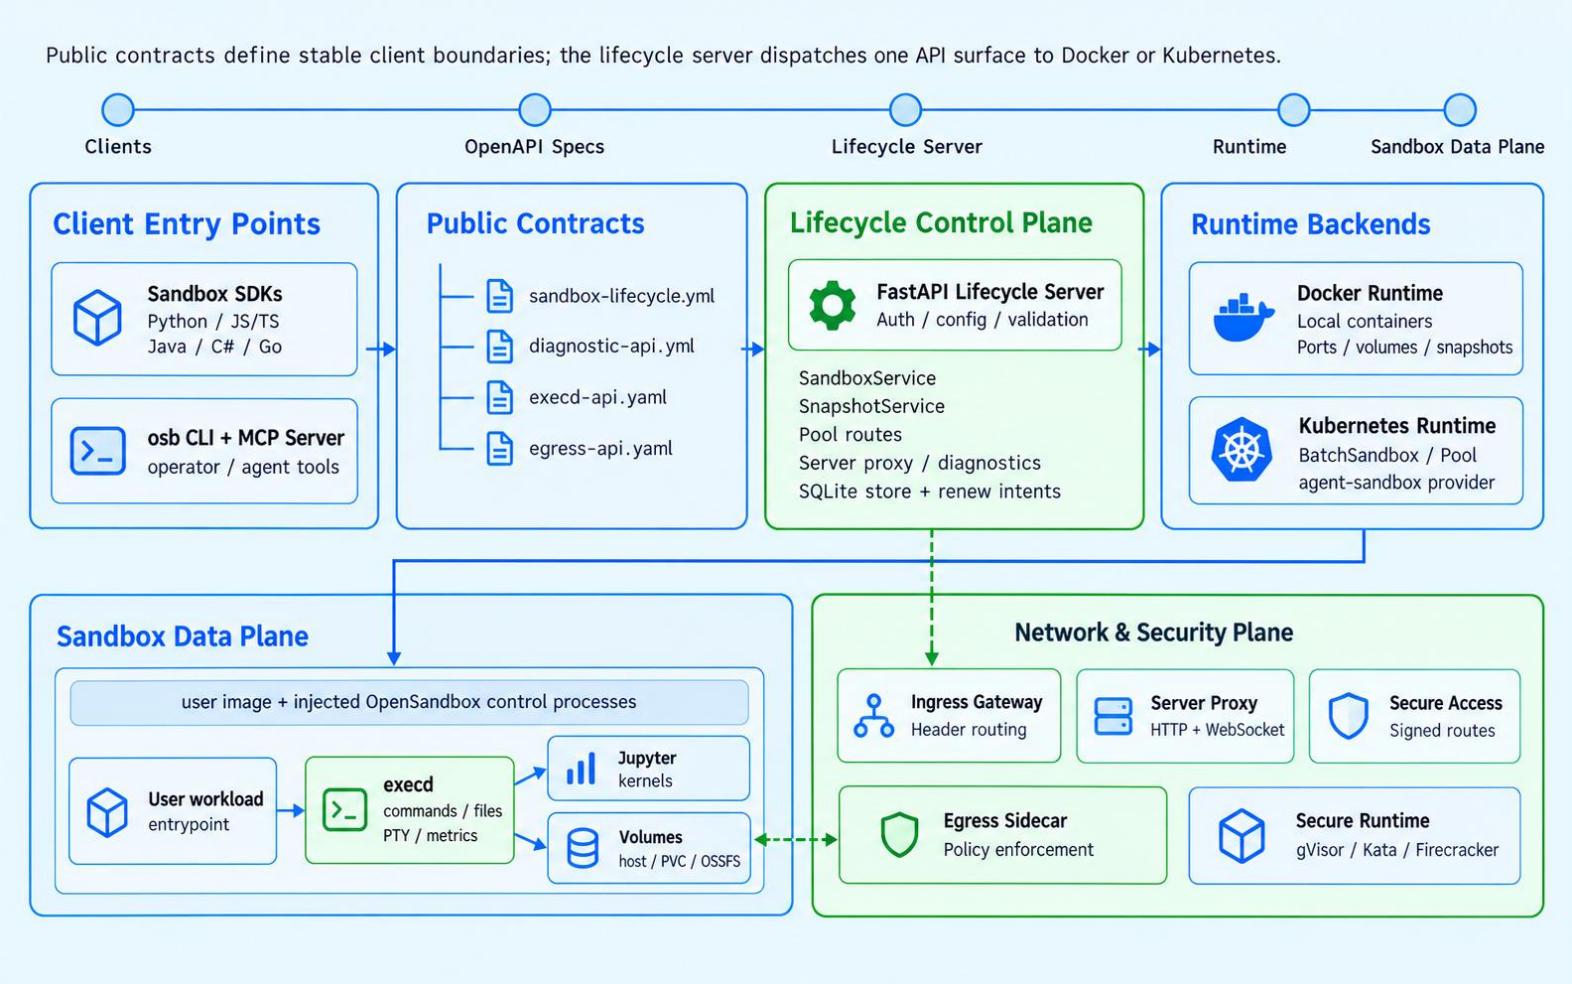
Open CodeReview

OpenCodeReview 成为阿里内部数万工程师日常使用的 AI 代码评审工具。运行了数百万的真实代码评审任务、拦截了数百万个真实代码缺陷。

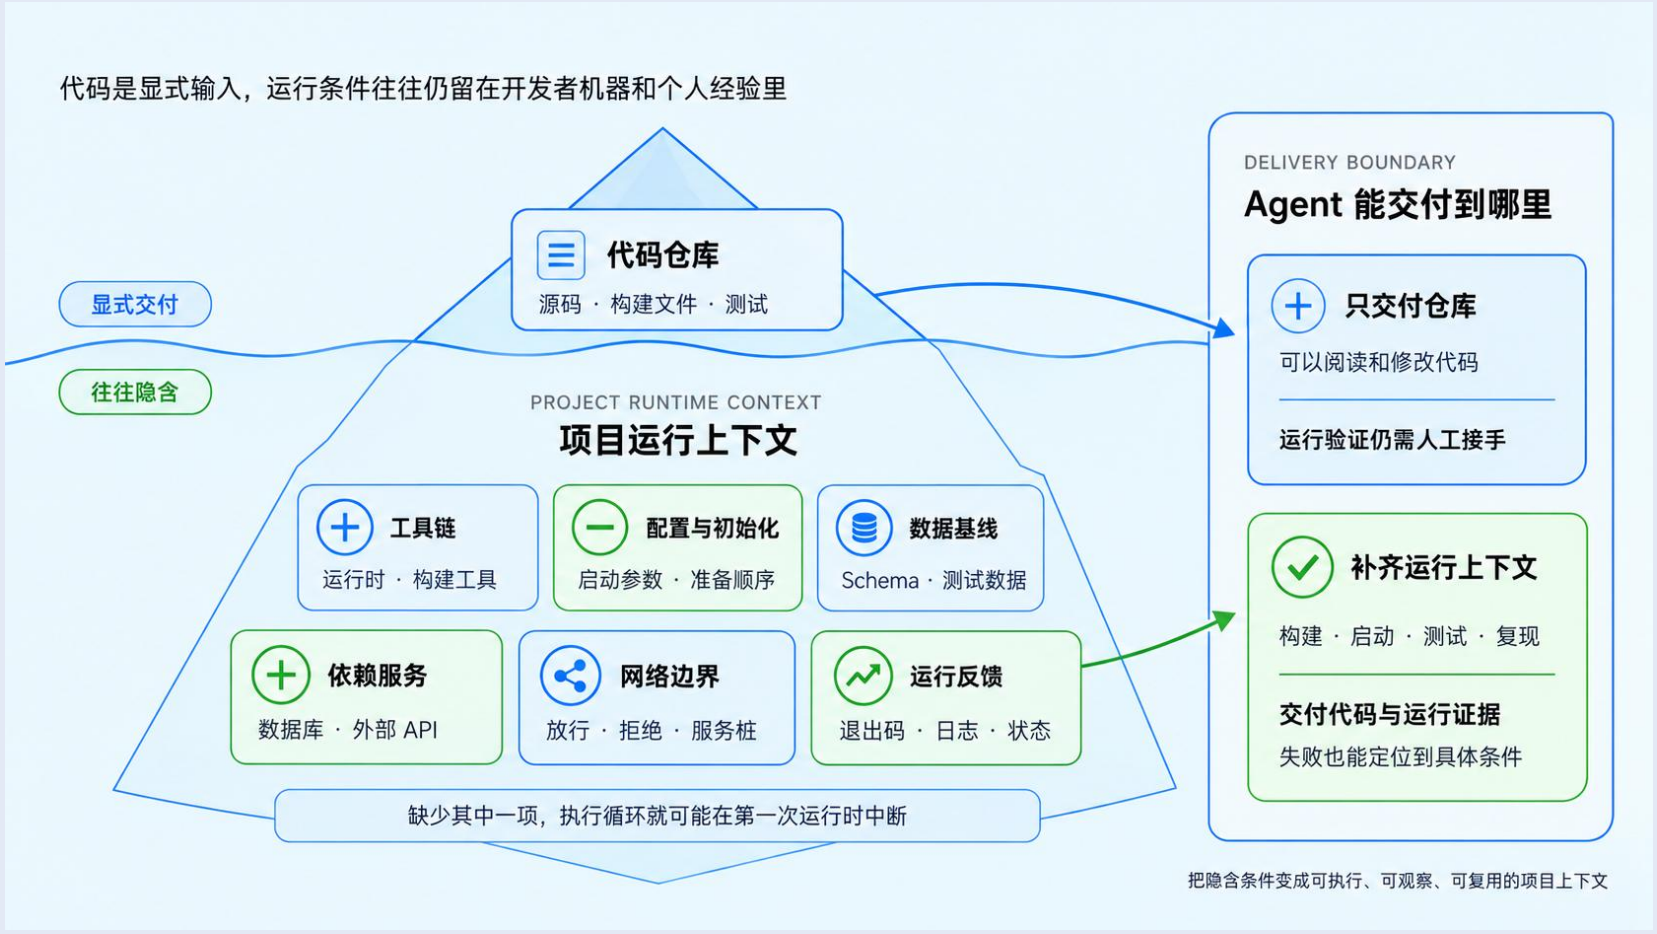


Open Sandbox

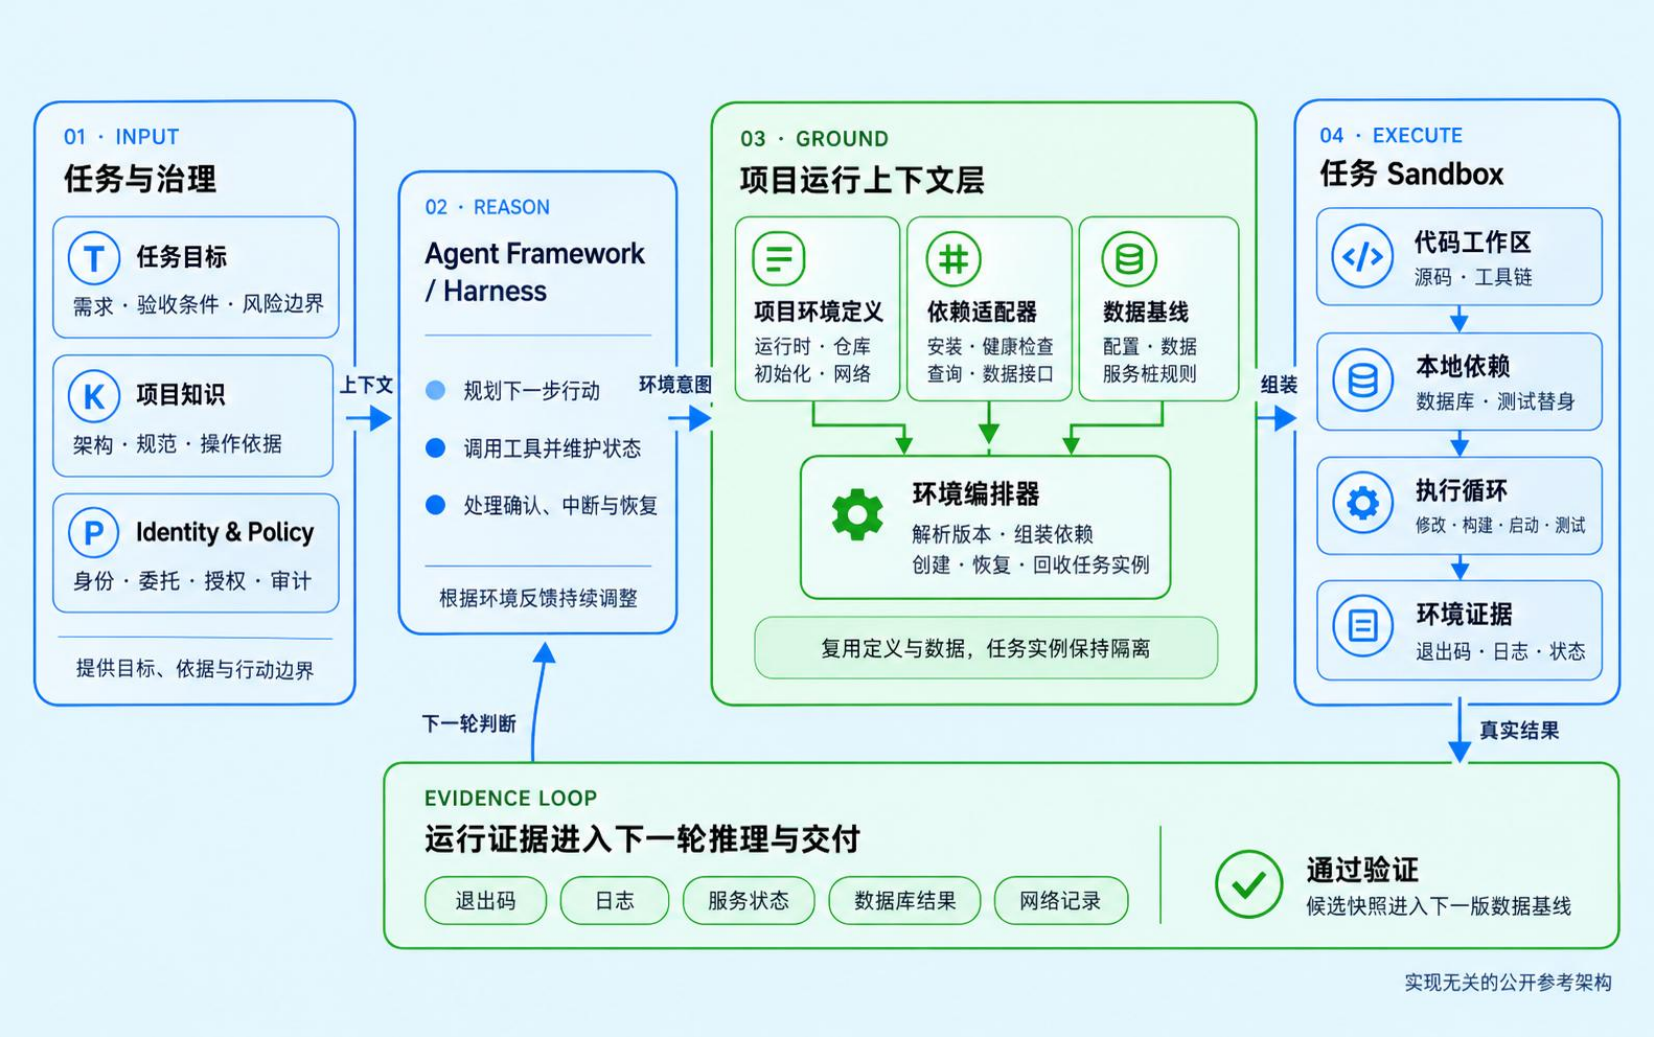
沙箱是环境验证的底层基础设施，目前在内部每天有数百万的创建量。



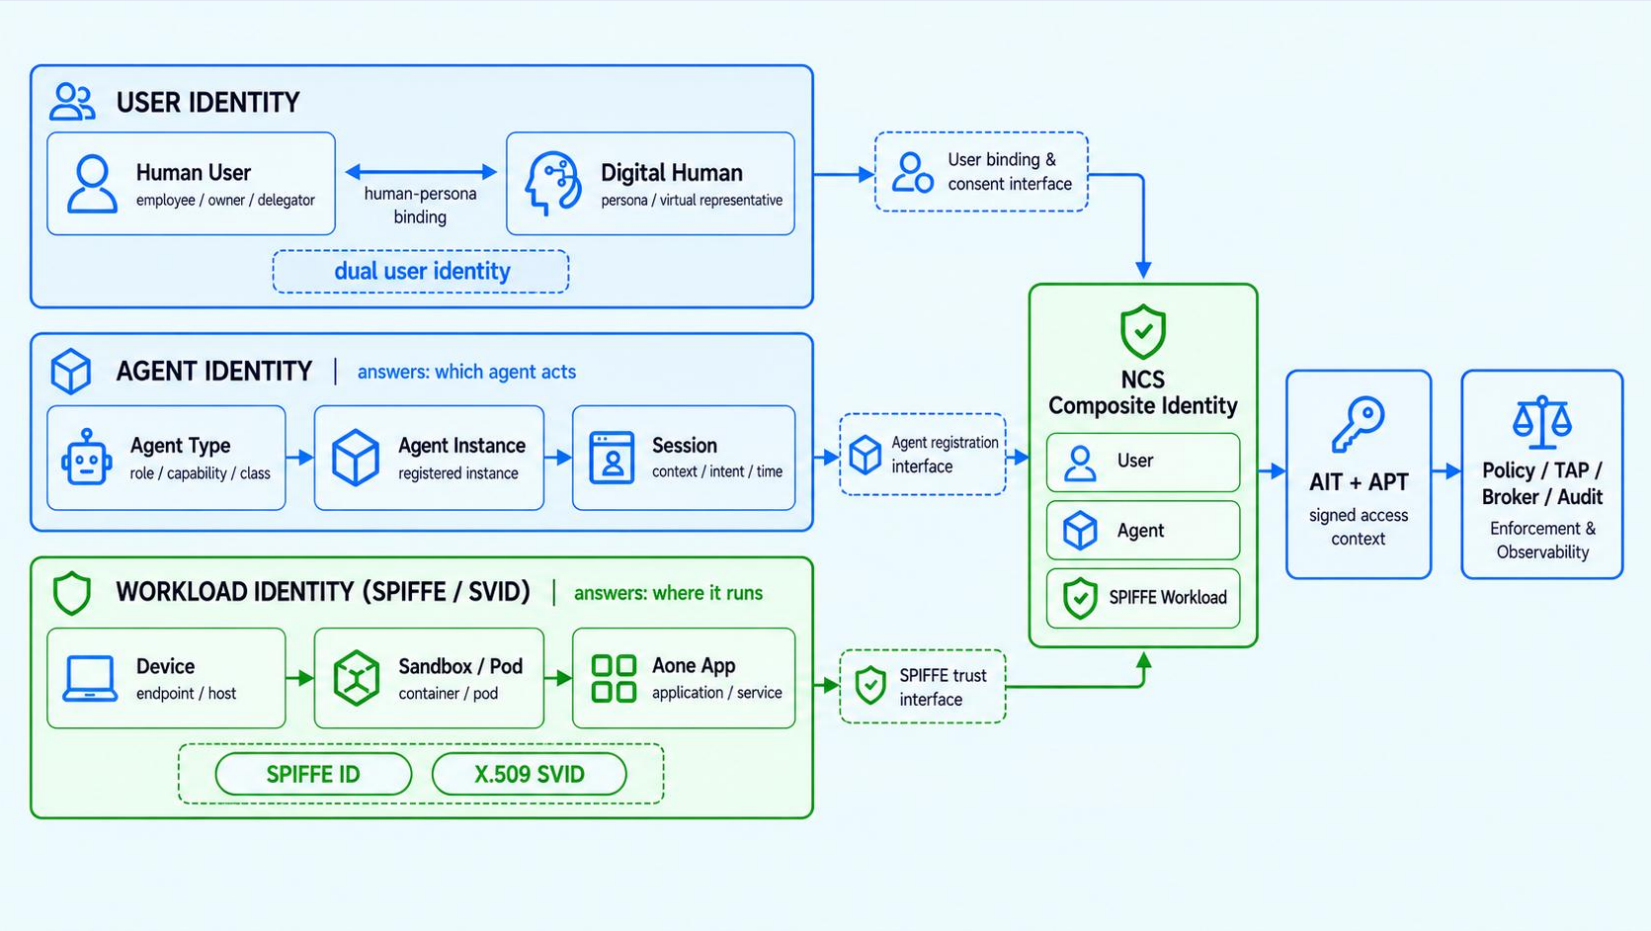
Aone Ground – 仓库只是验证环境的一部分



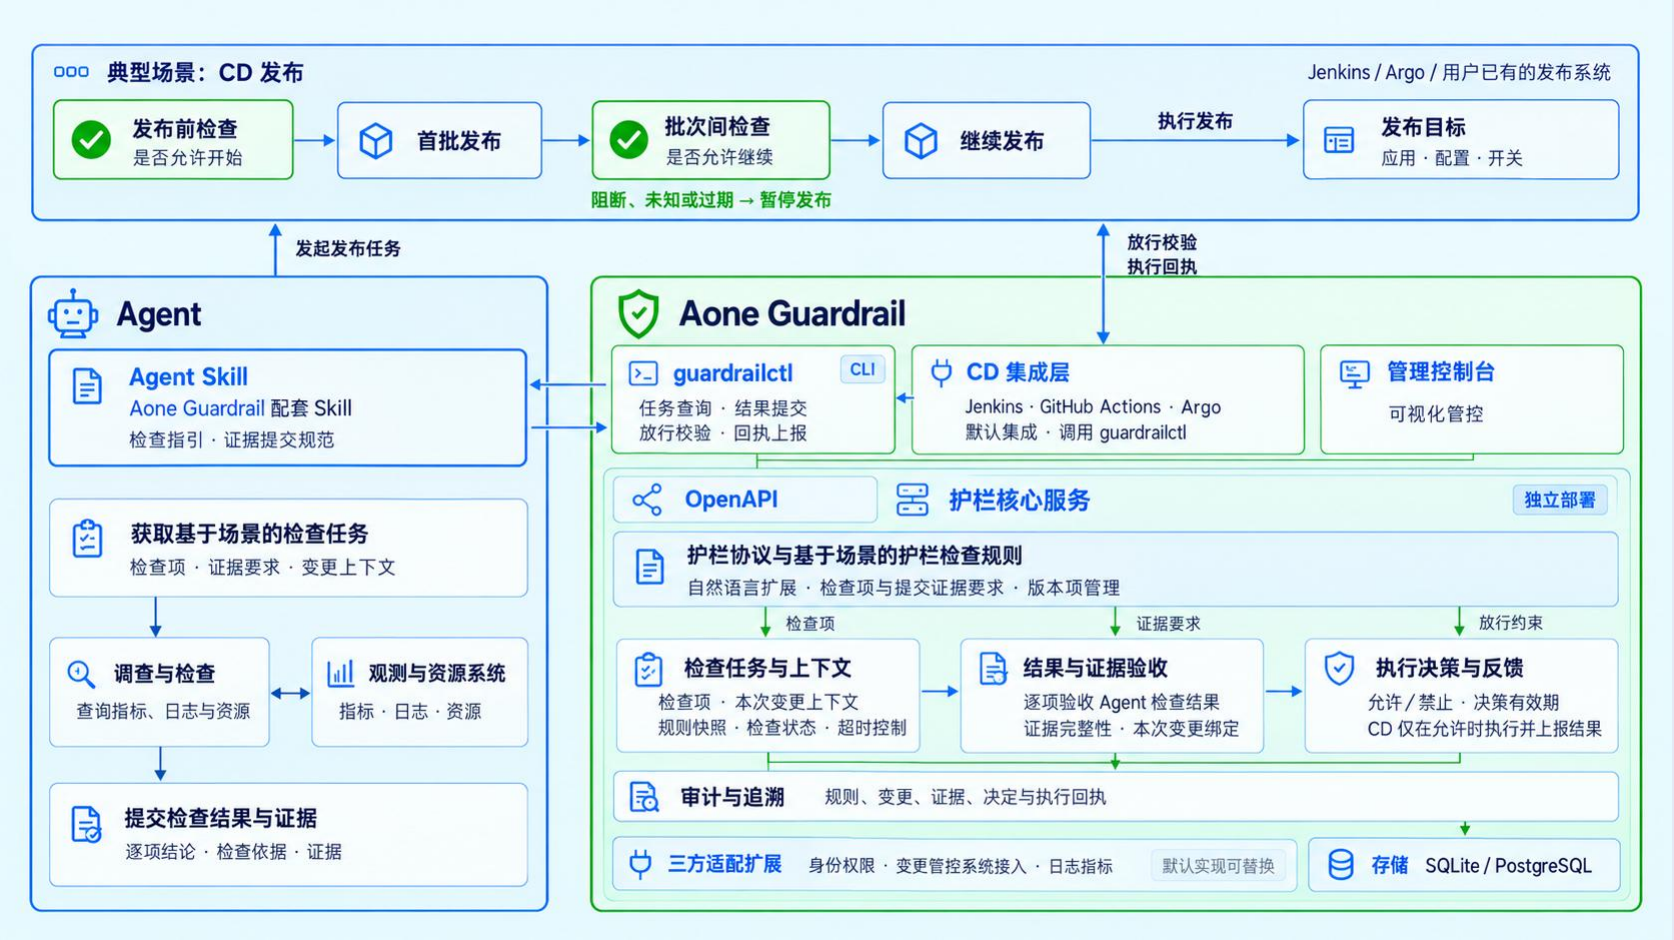
Aone Ground – 把环境做成可维护的对象



Open AgentAuth – 我们需要全新的身份系统



Aone Guardrail – 面向 Agent 重新设计发布系统



如何控制架构复杂度?

模型尚不能可靠控制架构复杂度

SWE-Milestone 论文所测模型：7 个仓库、98 个里程碑连续演化

Claude Sonnet 4.6 / scikit-learn

独立任务 Score

93.2%

连续演化 Score

21.1%

抽象边界错位

逻辑放错层级，破坏解析链契约并引入回归

测试通过，契约仍被破坏

全局抑制错误替代精确修复，删除必要 API

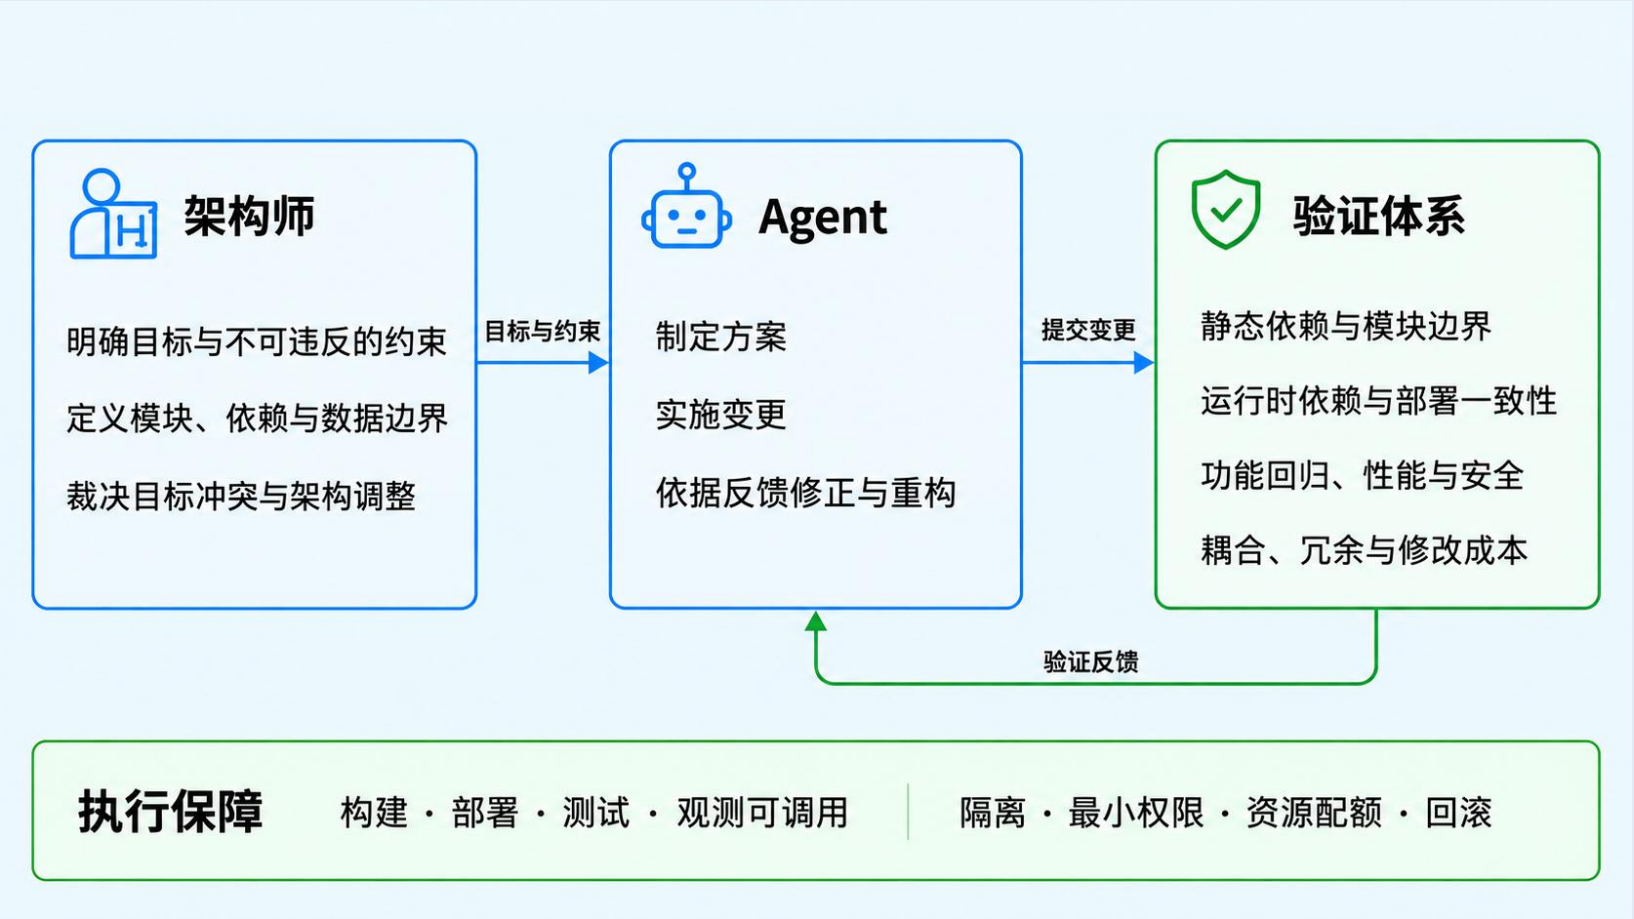
公共接口与可维护性退化

类型变字符串，重复逻辑与旧补丁被保留

工程判断：架构边界和长期演化，仍需人来把关

来源：SWE-Milestone，§5.2–5.5、附录 C.1（arXiv:2603.13428v4）

当下：需要架构师设定目标



AiCon 北京站

全球人工智能开发与应用大会

探索 AI 应用边界

Explore the limits of AI applications

2026 年 12 月 18–19 日 / 北京新云南皇冠假日酒店

参会咨询

专题：Post-Training Engineering | 数据、奖励与模型能力塑造



专题出品人：余瑶

飞猪 / 资深算法专家

专题：大模型推理与算力调度实践



专题出品人：范苑

阿里云 / 专有云计算产品负责人

专题：Knowledge Engineering | 让 Agent 理解企业



专题出品人：盛茂家

火山引擎 / Viking 团队技术负责人

专题：Loop & Graph Engineering



专题出品人：孙子荀

腾讯 / 腾讯高级总监

专题：AI 原生架构的演进与治理



专题出品人：刘中兵

快手 / 架构治理团队 & AI 架构演进负责人

专题：Agentic Software Engineering | 从代码生成到软件交付



专题出品人：杨杰

荣耀 / 首席 IT 技术架构师

QCon
全球软件开发大会

InfoQ 技术大会

THANKS

大模型正在重新定义软件

Large Language Model Is Redefining The Software

