Agent评估平台架构设计与业务落地实践分享 - 摘要

14:51 2026/10/23
上海市, CN
由AI生成，请在使用前核实

概览

本次分享系统介绍了面向业务Agent的评估平台架构设计，涵盖评估资产、评估控制与评估引擎三大模块及在线离线双轨闭环机制。核心共识在于平台侧重提供标准底座、链路数据提取与可编排流水线能力，而将指标加权与具体业务归因交由各业务方定制以实现轻量化协作。会议最终完成现场问答并宣布进入中场休息，后续仍有两场分享安排。

要点

- 评估平台与业务确立分工边界：平台提供底座框架、全链路Trace数据与评估流水线，下游具体指标结果消费与迭代归因由各业务方自行实现。
- 确立了评估资产三大核心要素，将数据集、评估器（代码/规则/LLM/定制Agent）及分层编排流水线均作为沉淀资产管理。
- 评估引擎架构正由依赖后端接口编排向代码化沙箱部署演进，以解决高并发大吞吐与深层Trace反序列化性能瓶颈。
- 构建在线与离线双轨闭环，通过线上流量采样、粗精两级筛选反哺黄金数据集，解决数据与评估器长期失效问题。

详情

- 评估平台与业务的合作定位
  - 平台与业务差异化分工：平台提供统一框架底座与标准化、可扩展能力，各业务根据自身关注点（如产品关注整体成本与明显低分样例，搜推广告则关注初筛倾向打分与多评估机制并发综合打分）按需配置。 00:01:51

    - 下游结果消费交由业务：平台仅负责运行评估并输出分值结果，不强行包揽下游打分平台逻辑与千人千面的迭代需求。 00:38:10

- Agent评估的多层级与多维度标准
    - 评估维度与层级划分：评估覆盖结果、中间节点与执行轨迹三个层次，支持结合正确性、准确性等维度由多个模型/规则共同评判。 00:10:43
        - 结果层评估输入输出的端到端回答质量。 00:11:14
        - 节点层评估意图识别分类一致性与Tool调用传参准确性。 00:05:44
        - 轨迹层评估Skill的MD文件加载情况及可观测排障经验流程的合理性。 00:05:35
    - 模型稳定性与确定性判定：同一Prompt或用例在多次回放后若回答结果差距巨大或出现错误，表明Agent确定性不足且存在明显质量问题。 00:36:32
- 评估资产与数据集建设
    - 评估资产三大组成：平台将数据集（黄金数据集/回归集）、评估器及串联各节点的评估流水线统一视作可复用的评估资产。 00:08:48
    - 数据集双来源与沉淀机制：初期由研发脑暴自建10-30条测试用例，上线后从生产真实流量中采样并通过粗筛、精筛沉淀入Golden Case。 00:14:55
- 评估流水线与Agent评估器定制
    - 评估器类型与实现模式：支持对比JSON固定结果的规则/代码评估器，以及多模型打分（如温度设为0）的主观LLM评估器。 00:16:55
    - 编排Pipeline数据清洗：流水线负责从Session与Trace数据中提取特定模块轨迹并转换成评估器所需参数，例如推荐业务可配置仅当推荐条目数大于等于3时才进入评估。 00:18:00
    - 定制Agent评估器实践：通用Agent仅用于新手入门，深入业务需通过平台提供查Trace/Span/Tag工具并由业务定制Agent评估器，解决原平台沙箱不支持写文件或特定Python语法导致的适配困境。 00:20:31
- 评估控制与在线离线双轨闭环

    - 离线实验对比：离线数据集用于在提示词修改或新版本上线时与线上基线对比，防止局部修改导致全局答案劣化。 00:25:07
    - 在线离线双轨闭环：线上针对点踩、耗时异常数据进行采样初筛（筛至约3%），评估后将异常用例回流离线数据集以防数据过时。 00:27:58
- 评估引擎架构演进与沙箱部署
    - 原工作流引擎瓶颈：基于DeepFlow等工作流调用后端模块存在并发漏斗限制（如单次限跑10个任务）、断点续跑开销大、图片等复杂Trace反序列化性能低及低吞吐（仅几百并发）问题。 00:28:40
    - 沙箱独立部署演进：将Pipeline配置直接转为独立代码包部署至沙箱，支持10万级大数据集Batch运行，用完即销毁并使用业务自身算力。 00:32:12
- 现场问答与业务实操问题讨论
    - 链路数据隔离定位：针对故障演练等测试数据侵入链路的疑问，指出传统架构下即需业务建立独立隔离链路，平台无法单方面解决。 00:43:19
    - 评估分化归因依赖人工：针对指标两升一降等多维度冲突，目前主要依赖人工核验判断是Agent问题还是评估器本身不稳定（如改动评估器导致总分剧变为4.5即属评估器误判）。 00:38:59
    - 历史Trace复写支持：针对工具调用随时间变化问题，讨论通过具备覆盖/复写链路数据能力进行故障重放复现。 00:46:10
    - 聚类归因由业务实现：平台提供粗筛（过滤至数百条），具体的Bad Case加权计算与聚类归因由业务端自行闭环。 00:48:17

后续行动

结束当前场次进入中场休息，稍后继续进行后续两场技术分享。