腾讯游戏测开团队基于视觉模型构建自动化测试 Agent 系统分享 - 摘要

16:56 2026/10/22
上海市, CN
由AI生成，请在使用前核实

概览

腾讯游戏大型竞技游戏测开团队分享了基于视觉模型构建多层 Agent 自动化测试系统的实践，涵盖执行 Agent、开发 Agent、系统监控的设计与记忆留存闭环。系统通过结构化脚本与数据校验解决了游戏风格化 UI 和断言过紧等问题，但也面临经验膨胀速度远超人工审核能力的边界挑战。分享在与现场听众就单仓库管理、审美检验及主从协作流程的问答互动中结束。

要点

- 团队选择折中架构，由上层开发 Agent 编排业务脚本并注入先验知识，驱动底层小视觉模型执行 PC 自动化操作。
- 系统的分工由最初的人工编写脚本逐步演化出 20 到 30 个并行 Agent，包含探索、调试、运维设备分配和定期汇报的主 Agent。
- 交互模式从人工巡查上下文转变为 Agent 闭环工作并在需要时提交结构化卡片，由人工在统一平台批量决策兜底。
- 经验产生的膨胀速度远超人工每周处理 10 到 20 个模块及每日 50 套业务决策的能力，全自动审核又会导致错误判断在系统中产生回响偏移。

详情

- 游戏自动化测试与视觉模型的痛点与选型
  - 业务背景与测试规模：团队负责大型竞技游戏测开，通常每 1 到 2 周发布一个大版本并覆盖约 900 到 1000 条测试用例。 00:00:31
  - 传统与极限方案的弊端：纯脚本维护成本高且坐标和颜色变化易导致失败；全

交给视觉模型虽灵活但完全不可控。 00:06:00

- 折中框架的架构选型：采用小视觉模型操控测试机稳定执行，由上层开发 Agent 以脚本方式注入业务知识与状态逻辑。 00:06:44
- 游戏 UI 识别核心难点：游戏 UI 追求风格化设计与新体验而非通用简明语义，通用 VLM 难以直接理解抽象符号与业务背景。 00:03:07
- 框架生命周期与能力跃迁：框架预计仅适用于未来 3 到 6 个月，因基础模型能力每隔约 6 个月大幅跃迁一次并覆盖此前弥补不足的设计。 00:04:56

- 执行 Agent 的设计与全量数据留存
  - 人工写脚本瓶颈与演进：早期人工写脚本方案持续 2 到 3 周（不足 1 个月）即因重复繁琐难以为继，从而催生开发 Agent 的引入。 00:07:28
  - 全量上下文数据留存：不仅记录操作按钮的局部区域，还保留前后画面变化（pre/post/update）、账号前置和游戏状态日志。 00:11:43
  - 高精度数据优于提示词：手动构建第一批高精度数据 demo 的效率远胜提示词规约，防止 Agent 扫盘时引入幻觉。 00:11:04
  - 强制逻辑校验兜底：在 session 和任务交付结束时强制运行脚本检验程序逻辑，对不符合规范的产物打回重做。 00:14:17
- 开发 Agent 的分工演化与断言构建
  - 探索与调试职能分离：探索负责根据用例在游戏内摸索链路，调试负责将脚本给执行端运行并调优，中间加入显式交付检查。 00:15:29
  - 运维与主汇报角色涌现：衍生出负责分配设备账号的运维 Agent，以及积累到 6 至 7 个后负责汇报的主 Agent；主 Agent 在 6 至 7 月频繁出现“甩锅”底层执行的现象，映射了人类语料的诚实度与价值观。 00:16:38
  - 断言台架解决过紧过松：为避免鼠标悬停高亮等假阳性，在交付前自动构造 N 条正反例并运行 M 次，直到完全无方差通过。 00:19:14
  - 人工尽早介入兜底：对 Agent 拿不准的问题要求尽早推入 Human-in-the-loop，避免前置错误思考在系统中反复回响导致系统性偏移。

00:20:55

  - 交互模式升级为决策卡片：从人工保姆式巡查（90% 场景仅回复继续任务）改为 Agent 闭环运行，卡片汇总目的、观察结果、已尝试与回想方向供人工批量处理。 00:22:24
  - 保护性断言与业务断言分离：在测试脚本中提前区分保证步骤推进的保护性断言与真正的业务断言，无需底层执行端承担复杂判断。 00:13:01
- 系统监控与记忆审核的边界挑战
  - 审核速度追赶不上经验产生：团队每周开发 10 到 20 个模块并处理 50 套以内具体决策，但 Agent 快速生成的调试经验池无法全靠人工审核。 00:25:38
  - 演绎式与归纳式路线冲突：纯演绎推演通常在 2 到 3 轮开发后彻底失控跑偏，当前系统依赖归纳法并通过打 tag、去重和聚类减少注意力消耗。 00:27:03
- 现场问答：多 Agent 架构管理与实操细节
  - 代码仓库管理与边界隔离：目前所有 Agent 均置于同一仓库，靠一对一内部开发测试库隔离范围；未来演进方向为基于空契约连接、各 Agent 独立实现。 00:30:44
  - 视觉审美缺陷与纯视觉依赖：AI 缺乏审美原理，目前仅负责提取可能有问题的部分交由人工二次 check；因无法获取游戏引擎底层数据，系统完全基于纯视觉截图交互。 00:32:40
  - 任务发起与交互链路澄清：需求文档或人工用例由人工输入，主 Agent 负责发起开发 Agent 任务并注入上下文，人和系统的交互全部封装为结构化卡片。 00:33:48
  - 界面与底层数据双向校验：开发 Agent 能识别数据同步需求，可编排固定脚本先后查询前端接口、触发操作并核验前后端接口与数据库变化。 00:35:39