记忆张量系统演化与参数化记忆模型技术分享 - 摘要

14:55 2026/10/22
上海市, CN
由AI生成，请在使用前核实

概览

记忆张量团队分享了记忆系统1.0的核心机制、面向个人助手与对话陪伴的记忆处理方案，以及参数化记忆模型Memory 1.0的技术演进与架构设计。分享重点阐述了通过参数化记忆替代复杂RAG流程并结合外部记忆系统的未来规划，并在最后的现场问答中解答了关于Memory T定位、多租户隔离、数据治理与通用Pipeline的疑问。

要点

- 团队推出了基于DeepSeek v4 Flash训练的参数化记忆模型Memory 1.0，在Transformer架构中新增Memory Attention层实现推理前向过程中的即时参数化更新。
- 当前Memory参数化记忆能力达到外置数据库约70%多的水平，大幅超越主流参数化记忆基线，未来规划通过与Memory系统结合逐步屏蔽繁琐的RAG流程。
- 记忆系统在向量数据库结合强ICL能力下已能达到极高准确率，图数据库在上下文较短或强推理场景虽能校正逻辑但实验提升通常不超过5%，且大幅增加工程复杂度。
- 面向对话陪伴场景提出了四层属性树模型，结合Michael Adam人格分层理论，通过身份锚点、长期角色、场景特征与即时情绪实现细腻的情感表达。

详情

- 记忆张量公司背景与记忆系统核心
  - 团队背景与研究路线: 团队自2023年5月成立，在欧阳院士带领下由科研与工程复合背景团队组成，先后研发Memorize与Memory T，探索结合内生参数化与外置增强的综合系统。

00:01:44

  - 记忆系统核心模块: 记忆系统包含信息抽取、组织存储、记忆检索应用、组装调度以及上层系统接入五大核心环节。 00:10:16
  - 调度层核心目标: 调度层主要解决大模型因上下文检索导致TTFT延长的问题，通过优化组装与调度降低首字延迟并增强准确度。 00:12:39
- 记忆系统1.0解决方案与处理机制
  - 向量与图数据库取舍: 向量数据库结合ICL可实现高准确率，而图数据库仅在实体因果关系强或上下文较短时有效，效果提升通常不超过5%但工程复杂度大幅上升。 00:14:21
  - 资产与权限隔离: 针对企业业务中技能代表资产的需求，系统在存储层设计了分组与多层级权限管理机制以保障资产共享与流通。 00:15:59
  - 算法与加速优化: 1.0方案集成了幻觉检测、关系识别、MCP接入支持以及利用QPATCH等手段实现推理输入加速。 00:17:45
- 任务轨迹提取与个人助手记忆处理
  - 三层轨迹记忆架构: 任务轨迹记忆自底向上分为Trace原始数据层、关键节点Scale提取层以及长程任务跨任务复用层。 00:25:41
  - 策略集成与控制机制: 引入证据、策略与控制机制避免单次测试引发策略突变，确保所提取Scale具备普遍适用性。 00:28:23
  - 个人助手评测表现: Memorize记忆处理方法在任务执行基准测试中，相比同类基线在Token消耗和任务完成度上均体现出优势。 00:28:47
- 对话陪伴系统的四层属性树工作
  - 理论基础: 系统基于Michael Adam人格分层理论构建，整合了人格特质、特征适应与状态特征的划分。 00:30:10
  - 四层属性树结构: 包含身份锚点（历史事实）、长期角色（性格数据）、场景特征（当前场景口吻判断）以及即时情绪（短时情感爆发）四层。 00:30:54
  - 属性树更新与感知: 从证据维度、重要程度和历史分析衔接三个维度判定更新

并训练LoRA增强感知，评测数据取自四部电影中的对话。 00:31:41

- 记忆延伸与参数化记忆模型Memory 1.0
  - 参数化记忆设计动机: 解决明文Prompt注入无法带来深度共情与推理进化的痛点，聚焦形成、分析和调用记忆，推动Memory for RSI及第二增长曲线。 00:34:38
  - Memory Attention架构: 模型结构中新增Memory Attention，包含将运行期数据写入参数的存储层与调度信息的应用层，支持新增、写入与遗忘等操作。 00:36:23
  - 训练基座与当前效果: 基于DeepSeek v4 Flash训练，记忆能力达到外置数据库的70%多，较传统参数化记忆方法具备数量级提升。 00:38:03
- Memory与Memory T的未来结合规划
  - 替代传统RAG流程: 旨在消除RAG在分片、Embedding、存储、召回及多轮重排上的繁琐链路。 00:39:30
  - 分工协同方案: Memory T负责推理侧能力增强与模型进化，Memory负责知识存储与检索加速，从而降低对外部数据库的强依赖。 00:40:23
- 现场观众提问与答疑交流
  - 答疑环节与主讲人: 分享由唐波老师主讲，现场开放了三个互动提问名额。 00:41:28
  - Memory T定位与更新机制: Memory T旨在直接替换通用基座模型，在前向推理过程中即可直接将信息参数化压缩写入记忆矩阵，无需额外构建RAG。 00:42:03
  - 多租户与模块隔离: 支持在数据层按用户维度和ID层进行隔离，推理引擎支持多个记忆块的动态装载与卸载。 00:42:46
  - Append-Only架构取舍: 纯Append-Only适用于追求速度的Memory T，而Memory OS 2.0因强调推理前置与Token复用优化，不会采用纯追加写入机制。 00:43:47

- 通用Pipeline与行业知识适配: Memory OS强调通用通路能力，面对特定垂直场景时需注入行业全局知识以避免通用Pipeline在新场景下的效果衰减。
  00:44:28